

Segmentacija slike

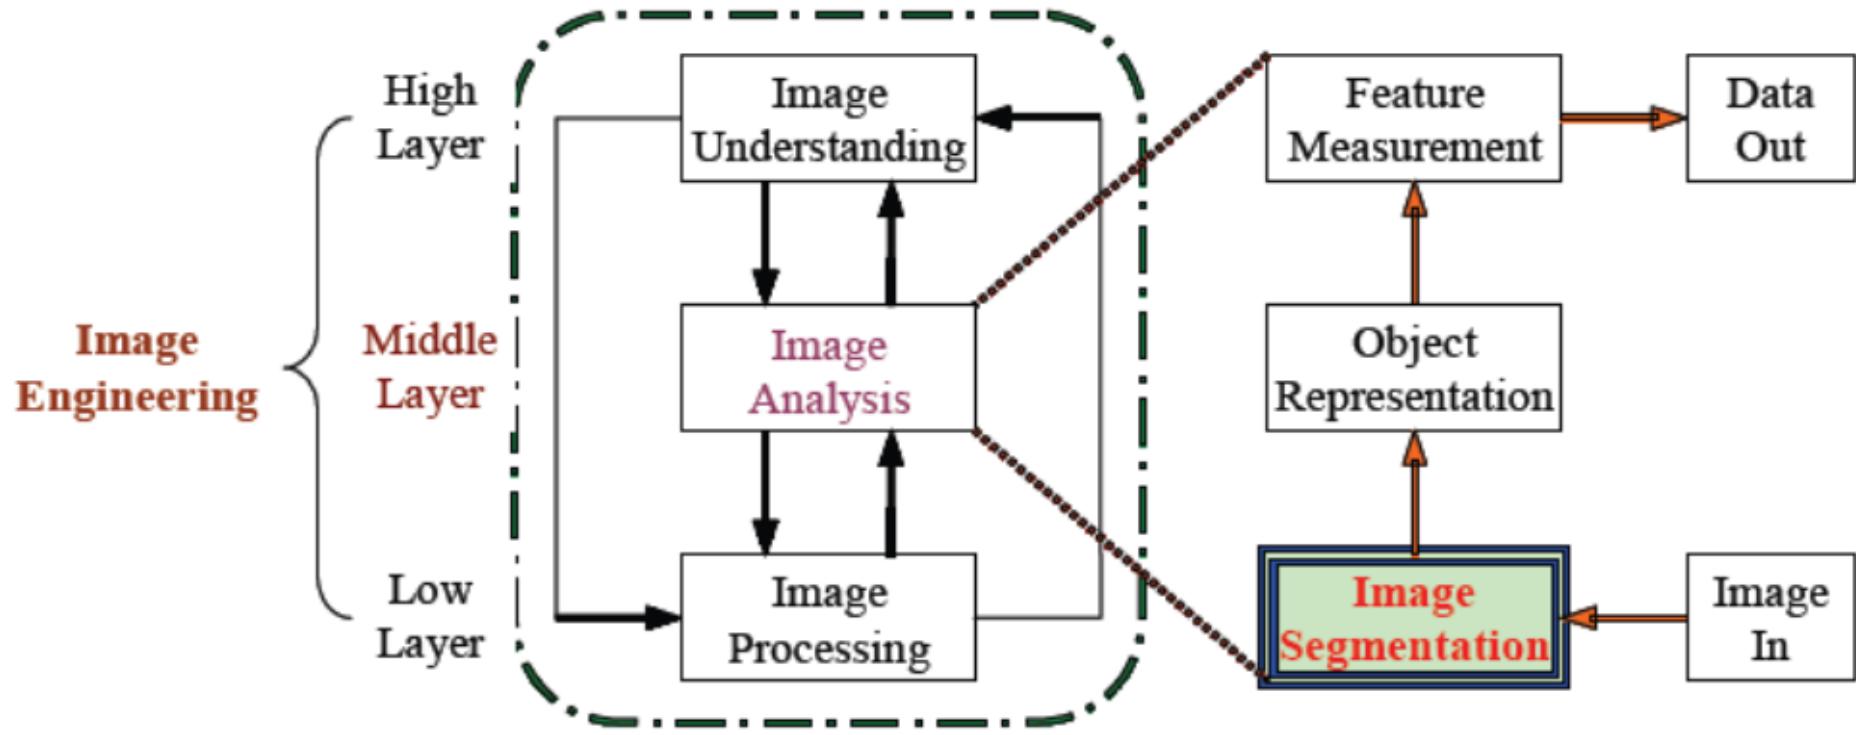
Pregled tehnika

Segmentacija slike – cilj

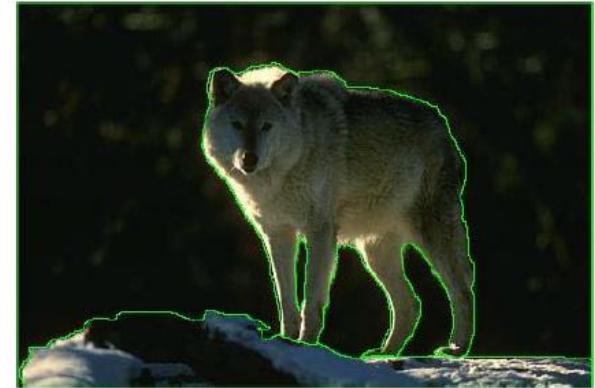
- Cilj: izdeliti sliku (ili video) na smislene regije
 - Na primer, možemo grupisati zajedno svetle regije, regije određene boje, regije sličnih karakteristika na medicinskim slikama, regije koje se pomeraju na isti način u videu,...
- Cilj segmentacije je da se pojednostavi i/ili promeni predstava slike u nešto što bi bilo smislenije i lakše za analizu
- Predstavlja jedan od ključnih koraka u analizi slike, predstavljaju objekata, vizuelizaciji,...
 - Rezultati segmentacije utiču na sve naredne procese analize slike
- MRI slike mozga
 - Detektovanje anomalija u mozgu zdrave individue
 - Praćenje stanja obolele osobe nakon terapije radi praćenja reakcije na terapiju i predikcije oporavka

Segmentacija slike – cilj

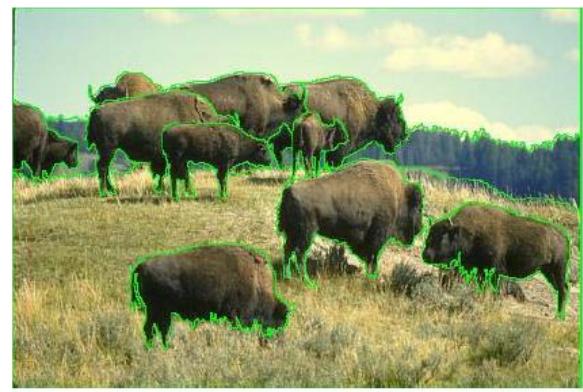
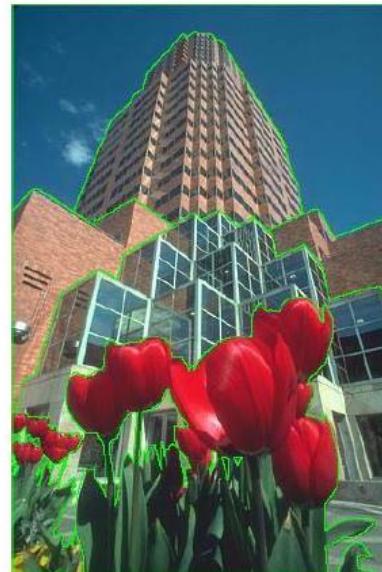
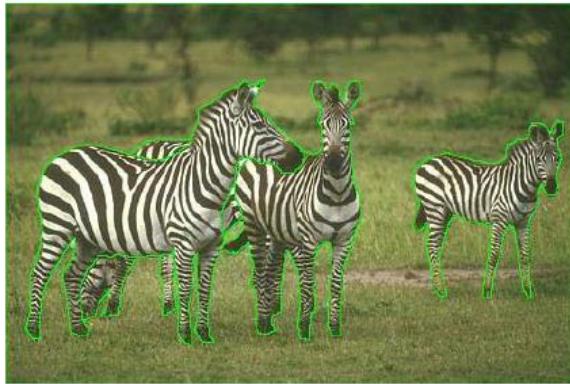
- Cilj: ekstrakcija informacija i reprezentacija objekta



Segmentacija slike – cilj



Segmentacija slike – cilj



Segmentacija slike – izazovi

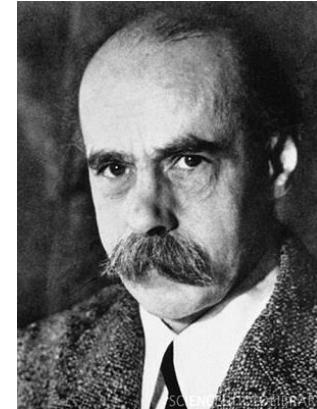
- Utvrđivanje *ground truth*
 - Manuelna segmentacija je dugotrajan i mukotrpan proces
 - Sem toga, rezultujuća segmentacija je subjektivna
 - Teška ili nemoguća za reprodukovanje
 - Subjektivne segmentacije različitih eksperata će se najverovatnije razlikovati
 - Zbog svega navedenog, trenutni stav je da se segmentacija evaluira u smislu krajnjeg cilja (celokupnog sistema čiji je deo)
 - Na primer, ako je segmentacija deo preprocesiranja sistema za klasifikaciju, performanse segmentacije se trebaju evaluirati u smislu performansi rezultujućeg klasifikatora
- Dvosmislenost podataka
- Šum
- Potreba za integracijom informacija visokog nivoa

Segmentacija slike – izazovi

- Celina je nešto veće i drugačije od zbira svojih delova

„I stand at the window and see a house, trees, sky. Theoretically I might say there were 327 brightnesses and nuances of color. Do I have „327“? No. I have sky, house, and trees.“

-- Max Wertheimer



- Šta definiše objekat?

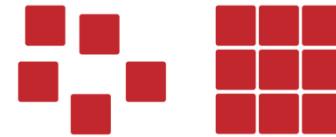
- Subjektivan problem, ali dosta izučavan
- Geštalt teorija (*Gestalt laws*) teži ovo da formalizuje
 - Geštalt – nemačka reč koja se prevodi kao „oblik“ ili „forma“ označavajući jedinstvenu celiku koja ima karakteristike koje su drugačije od njenih sastavnih delova i koja se ne može svesti na jednostavan broj elemenata ili delova od kojih je sastavljena
 - Šta je interesantno, a šta nije – zavisi od aplikacije

Geštalt principi

- Serija faktora koji utiču na to da li bi elementi trebali biti grupisani

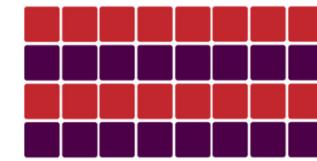
1. Princip blizine

- bliski elementi – ako su određeni elementi slični, oni će se verovatno smatrati jedinstvenom celinom, iako su to zasebni elementi



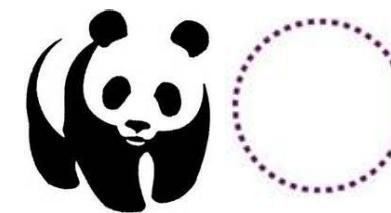
2. Princip sličnosti

- Kada su objekti sličnog izgleda, oko će često percipirati pojedinačne elemente kao deo određene šeme ili grupe
- Načelo sličnosti može se predstaviti kroz oblik, boju, senke ili druge grafičke elemente



3. Princip zatvaranja

- Predmeti poput oblika, slova, slike,... Se percipiraju kao celina i kada nisu potpuni



4. Princip simetrije

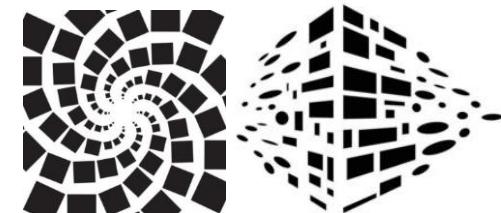
- Sličnosti između simetričnih objekata povećavaju verovatnoću da su objekti grupisani da bi se formirali kombinovani simetrični objekti



Geštalt principi

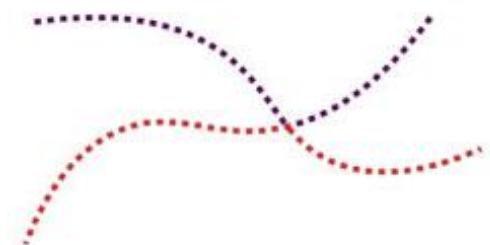
5. Princip zajedničke slobodnosti

- Elementi objekata percipiraju se kao da imaju trendove kretanja, koji ukazuju na putanju u kojoj je objekat uključen



6. Princip kontinuiteta

- oko preferira da vidi jednu kontinuiranu sliku duž određenog puta, linije ili krive



7. Princip dobrog geštalta

- Elementi objekata imaju tendenciju da se perceptivno grupišu zajedno i formiraju obrazac koji je redovan, jednostavan i uredan
- Pojedinci doživljavaju svet elimišući složenost, posmatrajući stvarnost u najjednostavnijem obliku



Geštalt principi

8. Princip prethodnog iskustva

- U nekim okolnostima, vizuelni stimulansi se kategorisu prema prošlom iskustvu
- Ako se dva objekta često posmatraju u neposrednoj blizini ili u malim vremenskim intervalima, verovatnije je da će se objekti sagledati zajedno



9. Princip figure i pozadine

- Percepcija je organizovana na način da se pojedini elementi u nekom trenutku ističu kao figura (lik) naspram nedefinisane pozadine
- Šta će biti figura, a šta pozadina u nekom trenutku, zavisi od karakteristika nadražaja ali i o interesu i nameri gledaoca.
- Nešto što je u jednom trenutku bilo figura može postati pozadina i obrnuto.



Definicija segmentacije

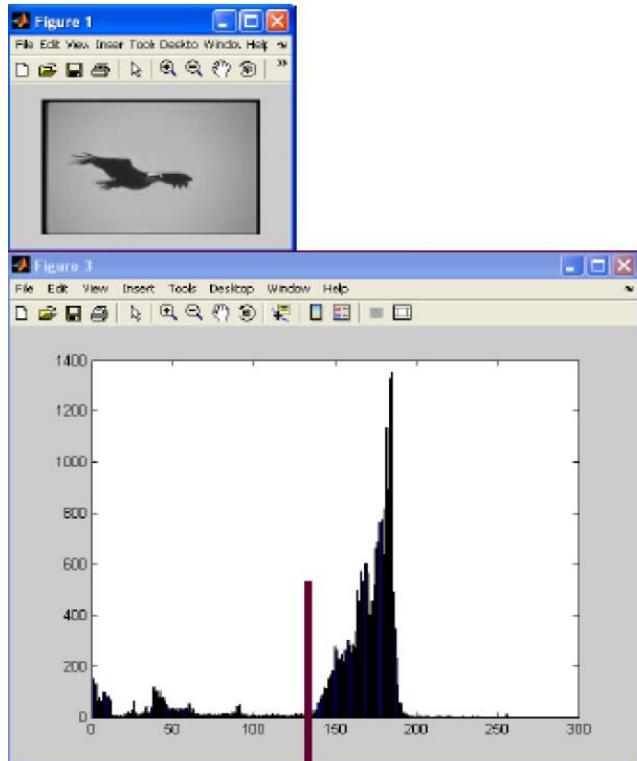
- Segmentacija slike je operacija particonisanja slike na kolekciju povezanih skupova piksela
- Neka R predstavlja celokupnu regiju slike. Segmentacija je particonisanje R na podregije R_1, R_2, \dots, R_n tako da važi:
 1. $\bigcup_{i=1}^n R_i = R$ – svaki pixel mora da pripada nekoj regiji
 2. R_i je povezana regija, $i = 1, 2, \dots, n$ (po definiciji susedstva)
 3. $R_i \cap R_j = \emptyset$ za sve i i j takve da je $i \neq j$
 4. $P(R_i) = \text{TRUE}$ za sve $i = 1, 2, \dots, n$ – uslov se odnosi na karakteristike koje regija treba da zadovolji (npr. svi pikseli u regiji su iste boje)
 5. $P(R_i \cup R_j) = \text{FALSE}$ za $i = 1, 2, \dots, n$ – različite povezane regije su međusobno različite u smislu karakteristika koje uniformna regija treba da zadovolji

Segmentacija slike

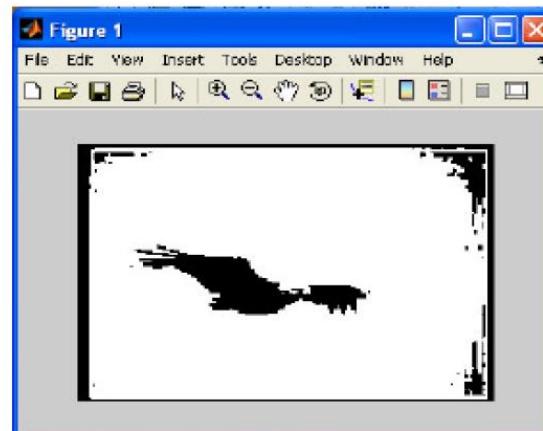
- Dakle, sve što treba da uradimo jeste da definišemo sličnost (homogenost)
 - Ali, šta je to što želimo da bude slično u svakoj regiji?
 - Da li možemo izdvojiti kriterijume koji će rezultovati time da regije budu objekti od značaja?
- Primeri pristupa:
 - Pristupi bazirani na histogramu
 - Pristupi bazirani na klasterovanju
 - *Region growing*
 - *Split-and-merge*
 - Morfološki pristupi
 - Pristupi bazirani na grafovima

Segmentacija bazirana na histogramu

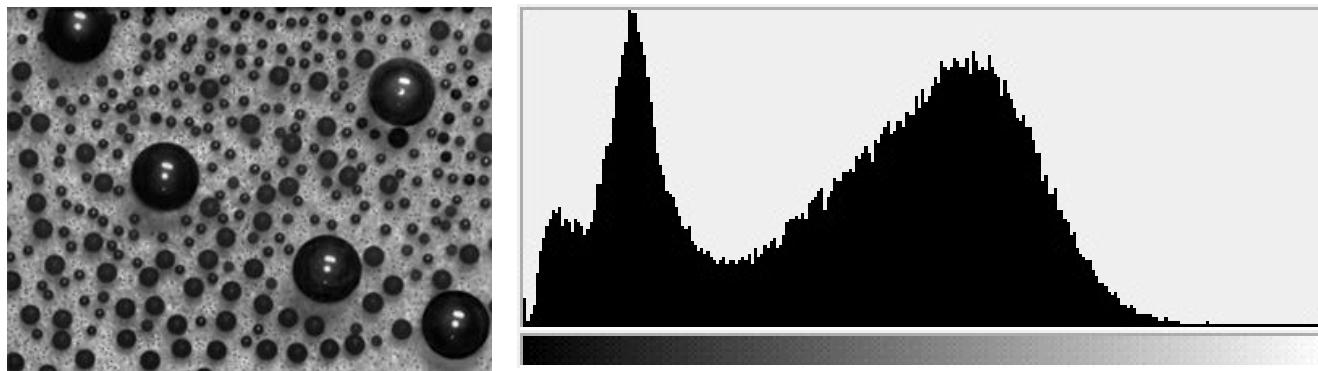
- Koliko „naradžastih“ piksela ima na slici?
- Na ovaj tip pitanja se može odgovoriti posmatranjem histograma



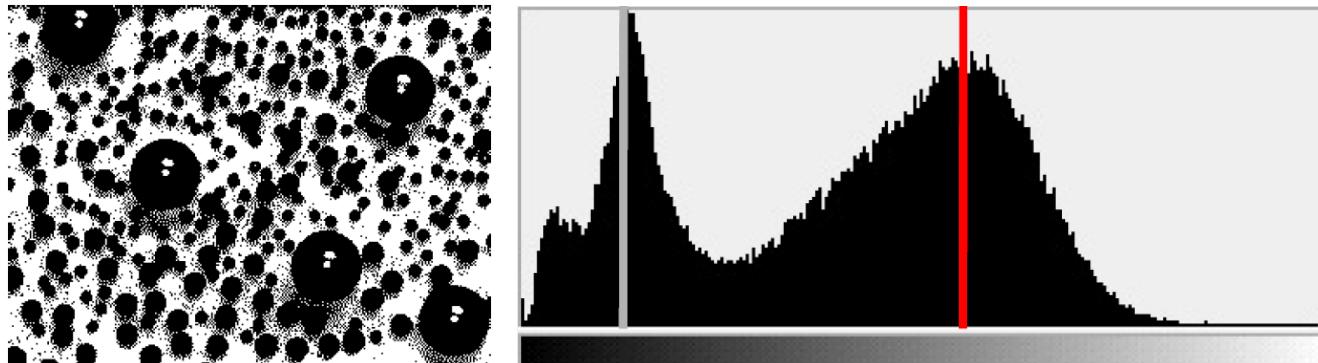
`imshow(B > 140)`



Segmentacija bazirana na histogramu

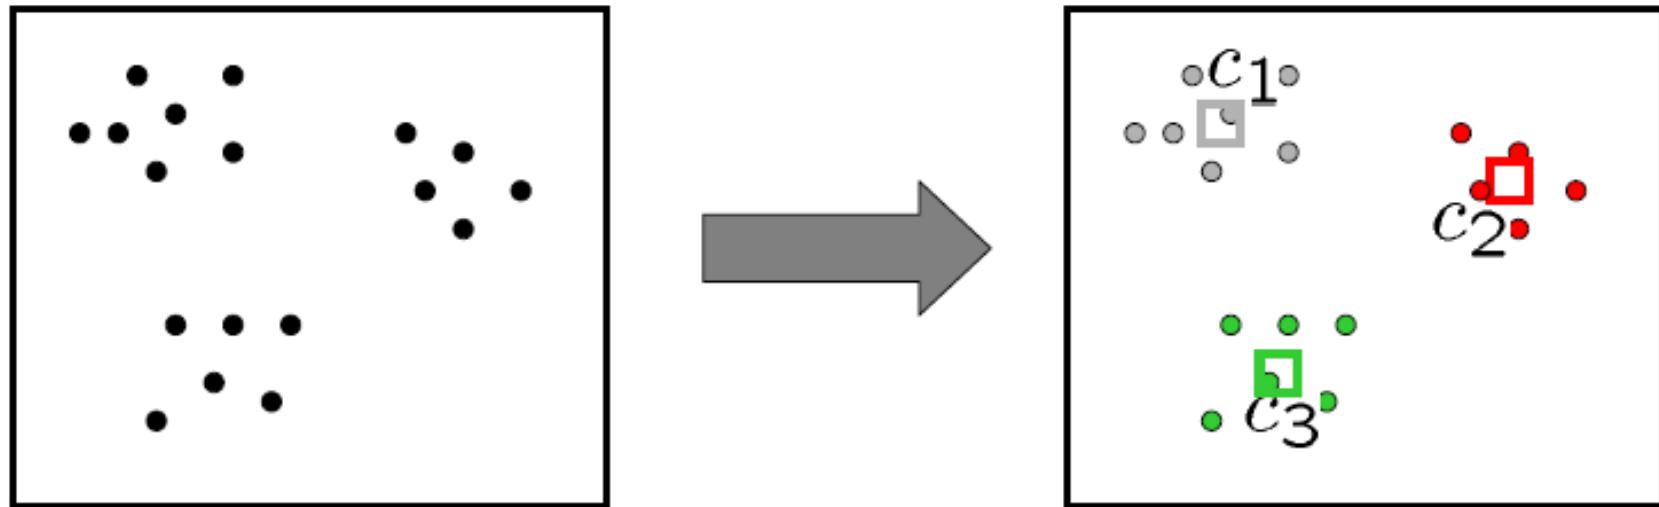


- Koliko modaliteta ima na slici?
- Ovo možemo rešiti tako što smanjimo broj boja na K i mapiramo svaki piksel na najbližu boju
- Na primer, ako koristimo dve boje:

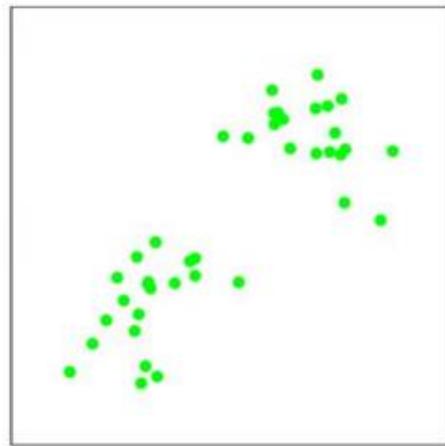


Segmentacija bazirana na klasterovanju

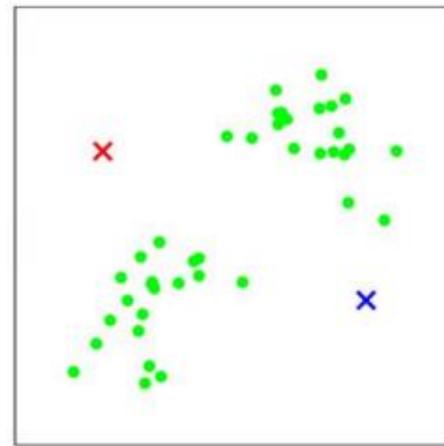
- Kako odabrati reprezentativne boje?
 - Klasterovanjem, na primer, *k-means*



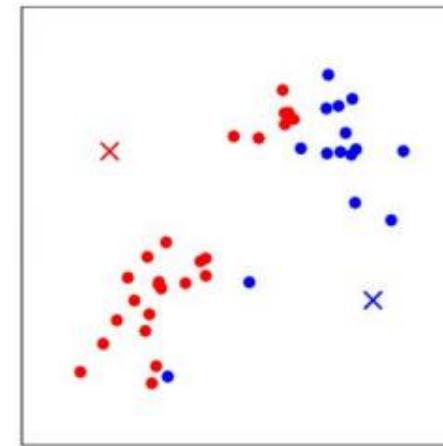
K-means



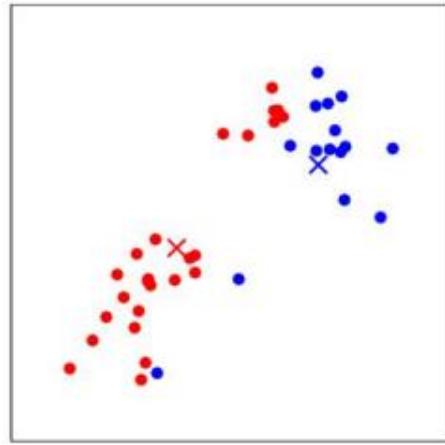
(a)



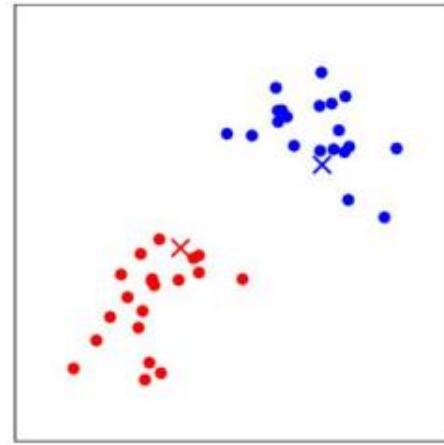
(b)



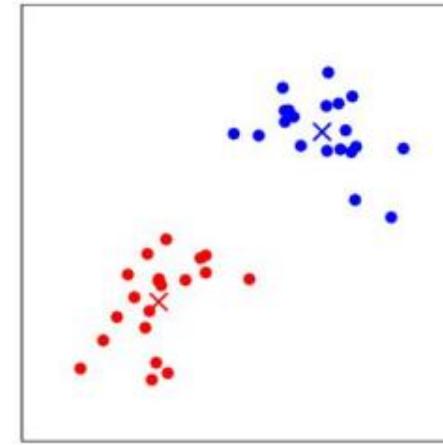
(c)



(d)



(e)



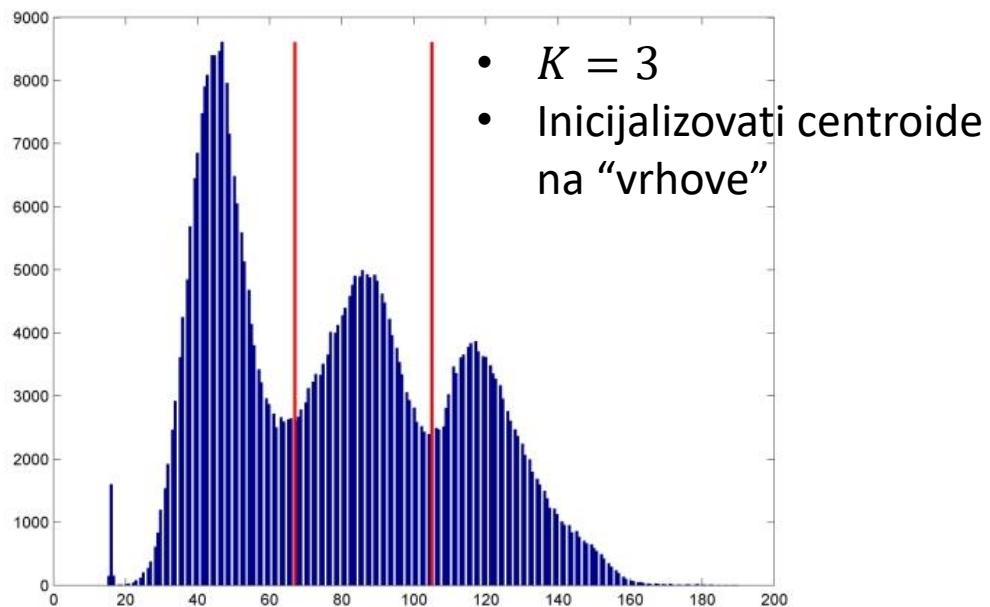
(f)

K-means

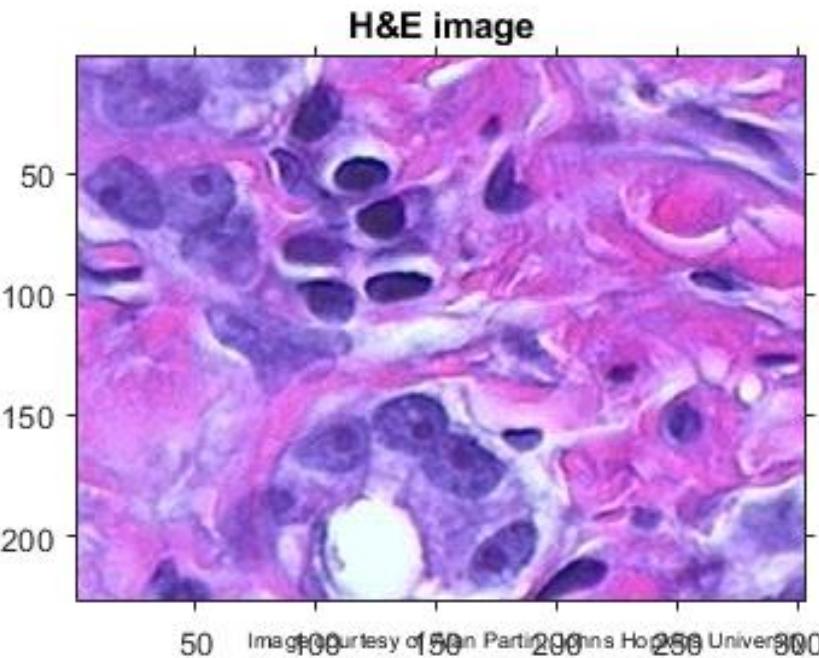
Ulaz	<ul style="list-style-type: none">• $T = \{x^{(i)}, i = 1, \dots, N\}$ – trening skup• k – broj klastera
Postupak	<ul style="list-style-type: none">• Na slučajan način inicijalizovati centroide μ_1, \dots, μ_k• Dok ne dođe do konvergencije:<ul style="list-style-type: none">• Za svaku opservaciju $x^{(i)}$ pronaći klaster sa najbližim centroidom (i dodeliti opservaciju tom klasteru):$z^{(i)} \leftarrow \arg \min_j \ \mu_j - x^{(i)}\ _2^2$• Ažurirati centroide klastera prema opservacijama koje su im dodeljene (<i>mean</i>)$\mu_j = \frac{1}{n_j} \sum_{i:z^{(i)}=j} x^{(i)}$$n_j \text{ - broj opservacija u klasteru } j$
Izlaz	<ul style="list-style-type: none">• $\{(x^{(i)}, z^{(i)}), i = 1, \dots, N\}$

Segmentacija bazirana na klasterovanju

- Varijante *k-means* algoritma:
 - Različiti načini inicijalizacije centroida
 - Različiti kriterijumi stopiranja
 - Dinamičke metode za određivanje korektnog broja klastera (k) za datu sliku



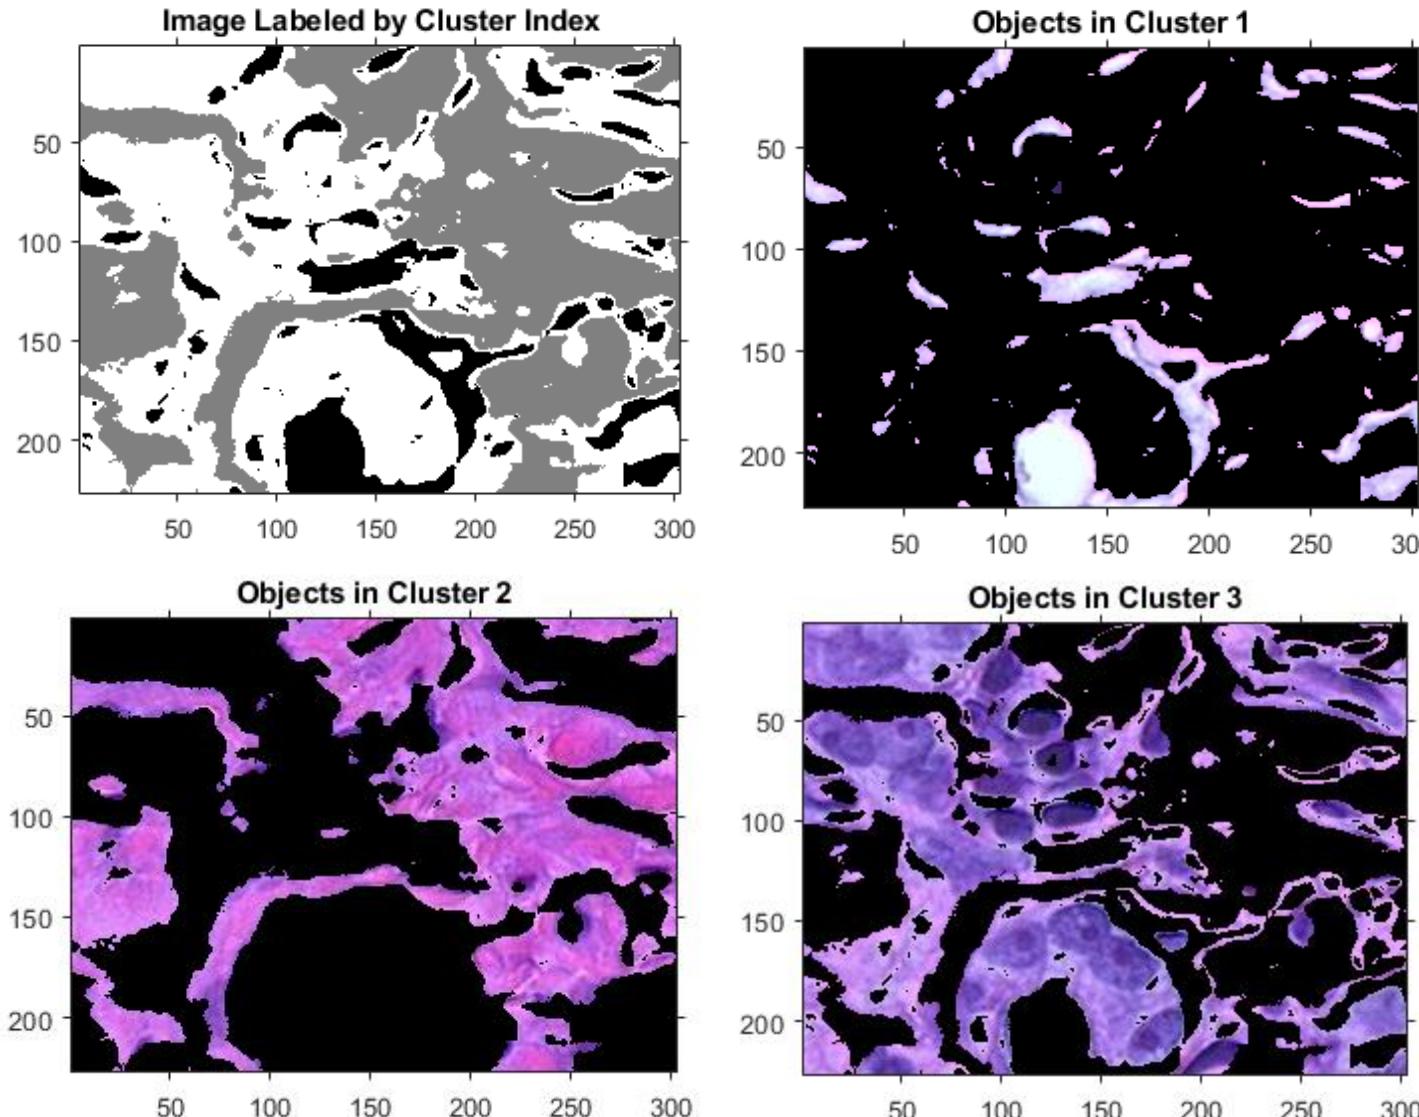
Klasterovanje prema boji – primer



- Slika: mikroskopski snimak tkiva obojenog hematoksilinom i eosinom
- Ovo je standardna metoda koja pomaže patologima da razlikuju tipove tkiva
- Želimo da klasterujemo tkiva prema boji

- Želimo klasterujemo po boji (nezavisno od osvetljenja)
 - Koristimo LAB model boja (L - osvetljenost, A – gde se boja nalazi na crveno-zelenoj osi i B – gde se boja nalazi na plavo-žutoj osi)
 - Koristimo samo informacije iz A i B
 - Na slici su prisutne plava, bela i ružičasta boja → tri klastera

Klasterovanje prema boji – primer



Ako dalje želimo da izdvojimo jezgra
ćelija (tamnije boje)
možemo da koristimo L kanal i globalni prag

Primer: *k-means* klasterovanje po boji

1. Select an image: imgs/Pa170028.jpg

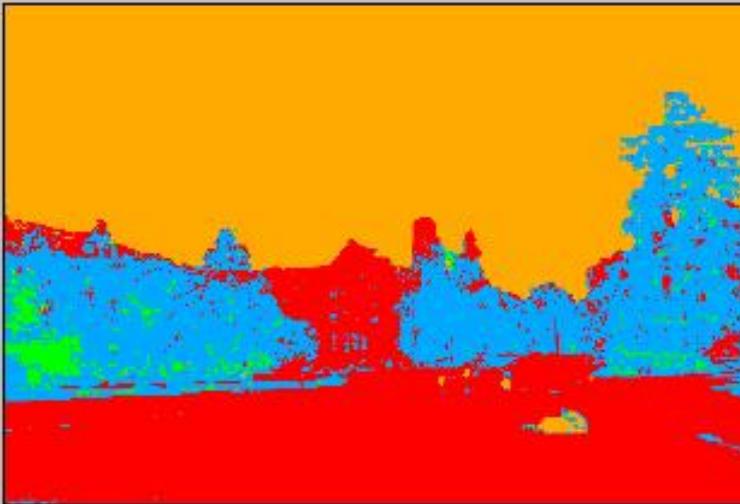
2. Select a processor: KMCluster

3. Click process>>

Options:
Init Method: 0



640*480 (607,118): RGB(20,22,1)



Process done!

(228,26): RGB(255,170,0)

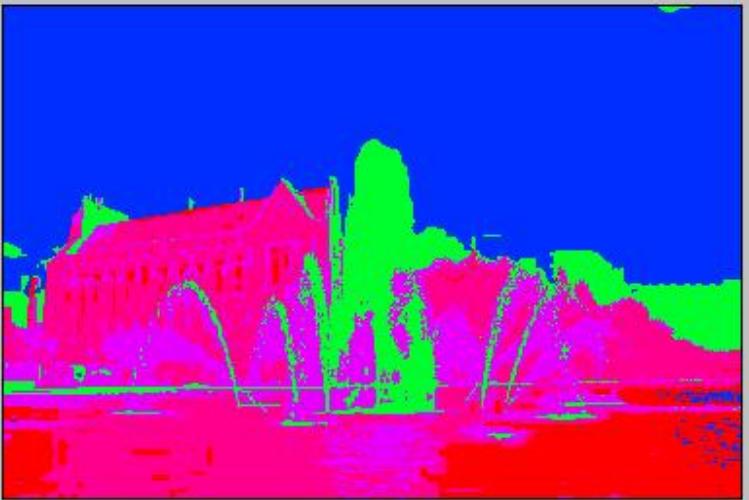
Primer: *k-means* klasterovanje po boji

1. Select an image: 2. Select a processor: 3. Click

Options:
Init Method

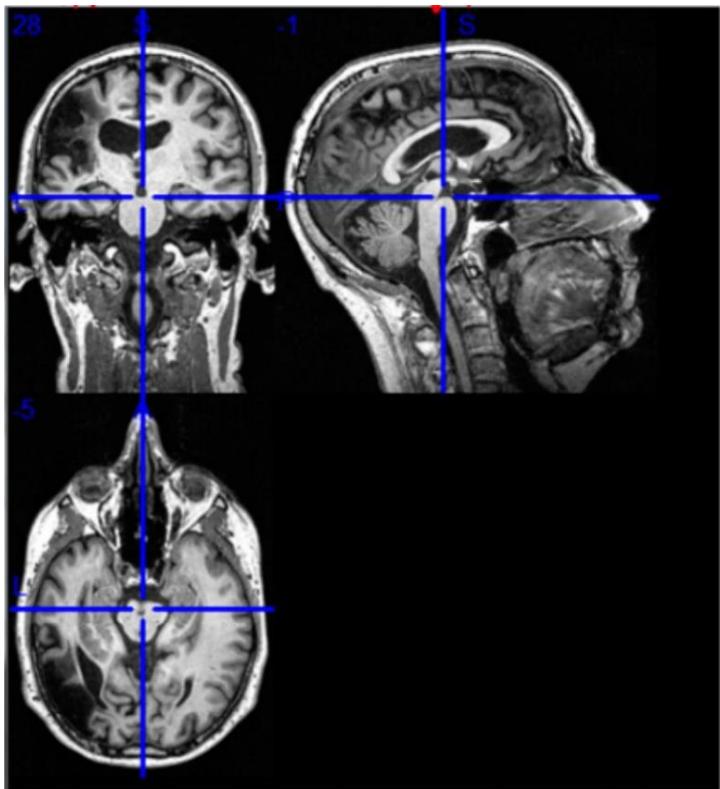


640*480 (636,95): RGB(102,130,151)



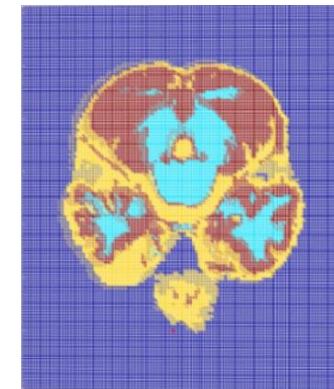
Process done ! (590,209): RGB(0,46,255)

Primena: procesiranje medicinskih slika



- MRI snimak. Na ovim snimcima postoje tipično tri grupe:
 - *White matter*
 - *Gray matter*
 - *Cerebral Spinal Fluid (CSF)*
- Želimo da klasifikujemo voksele (3D piksele) u ove tri kategorije
- Domensko znanje:
 - Vokseli istog intenziteta treba da pripadaju istoj grupi
 - Susedni vokseli treba da pripadaju istoj grupi

$$v(x, y, z) = \begin{bmatrix} \alpha \cdot I(x, y, z) \\ \beta \cdot x \\ \beta \cdot y \\ \beta \cdot z \end{bmatrix} \quad D(v_i, v_j) = \|v_i - v_j\|$$



Primena: procesiranje medicinskih slika

Segmentation

Grey matter

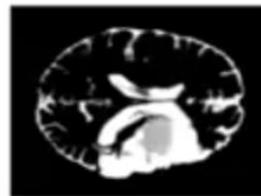
White matter

CSF

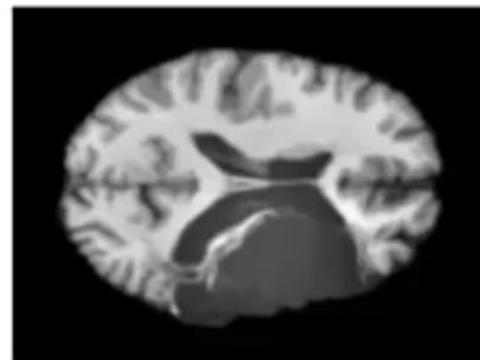
K-means
Segmentation



SPM8
Segmentation

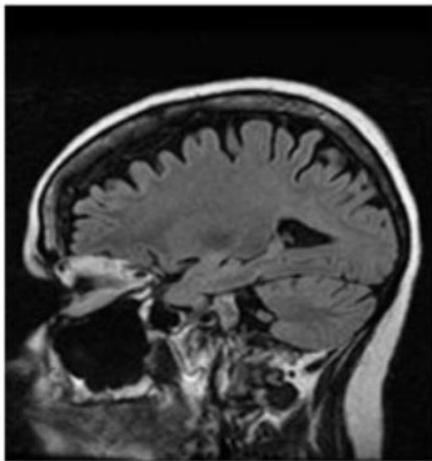


Original Image

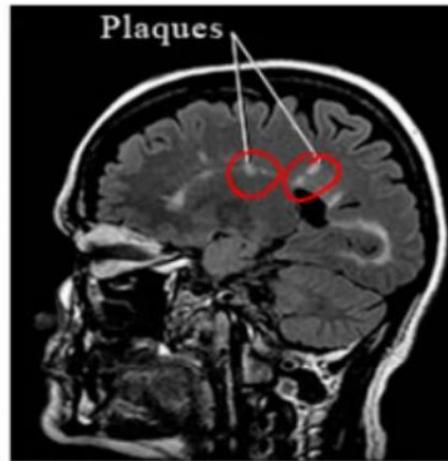


*SPM8 is a public toolbox supported by Matlab

Primena: procesiranje medicinskih slika



Healthy Brain

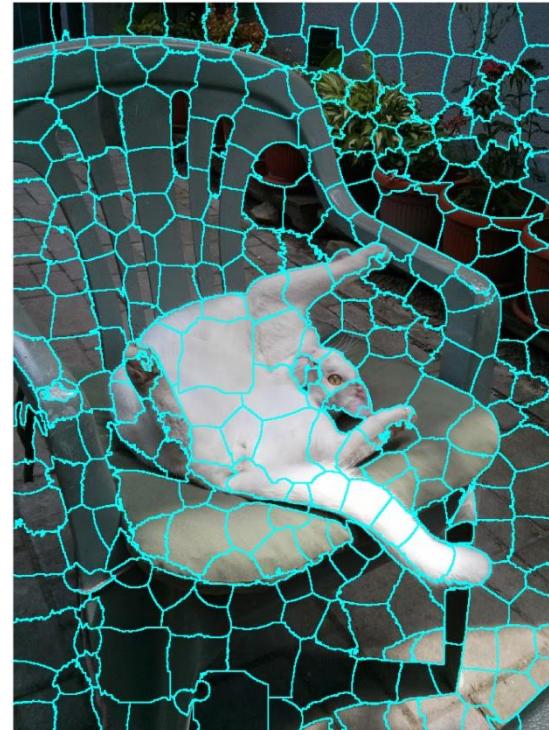
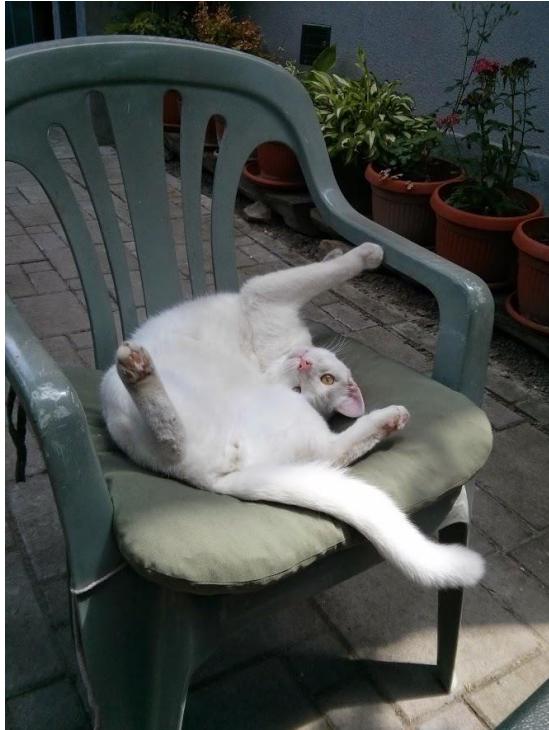


Brain with damage
(Lesions or plaques)

- Primena: pokušaj da se identifikuju
 - *Stroke lesion*
 - *Perilesional region*
- Ovo bi pomoglo da se predvidi oporavak ili reakcija na terapiju
- Tipično, ovo se crta ručno, što je vremenski zahtevan i subjektivan proces
- Problemi: šum, slabe ivice, nehomogenost podataka

Superpixels

- Rezultati koje smo dobili *k-means* klasterovanjem u odnosu na boju (ne i lokaciju) nisu loši u odnosu na izdvojene boje
- Međutim, izdvojene oblasti su dosta diskonektovane. Želeli bismo malo više prostorne koherentnosti
- Modifikacija *k-means* koja se često koristi u obradi slike: *superpixels*
 - Pronalaze se kontinualne regije koje su sličnog intenziteta/boje



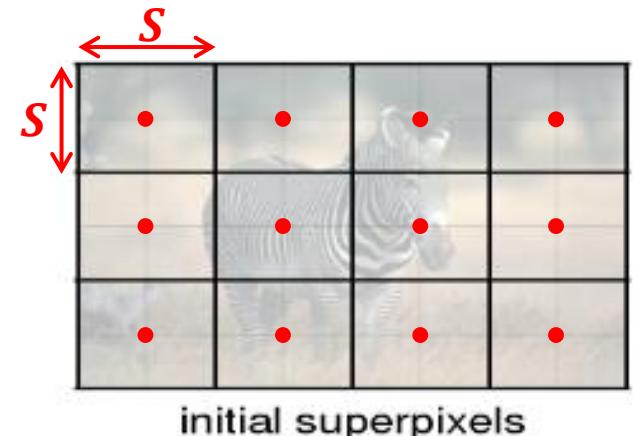
Superpixels

- Kompaktna reprezentacija slike
 - Sa hiljade superpiksela možemo predstaviti milione piksela
- Bolja reprezentacija za kasniju segmentaciju
 - „drži stvari zajedno“
 - Algoritmi za segmentaciju će biti efikasniji ako koriste superpiksele umesto piksela
- Algoritam
 - Modifikacija *k-means*
 - Pored boje se koristi i prostorna povezanost
 - Jedna varijanta algoritma: SLIC (*Simple Linear Iterative Clustering*)

SLIC (*Simple Linear Iterative Clustering*)

- Klasteruje se 5D vektor $[l, a, b, x, y]$
 - (l, a, b) - LAB model boja; (x, y) - prostorna informacija
1. Inicijalizacija centroida $C_k = [l_k, a_k, b_k, x_k, y_k], k \in \{1, \dots, K\}$ odabirom piksela na regularnoj mreži koraka S

- Pomeriti centroide na poziciju sa najmanjim gradijentom u 3×3 susedstvu
- Time izbegavamo da postavimo centroide na ivicu ili na piksel koji predstavlja šum

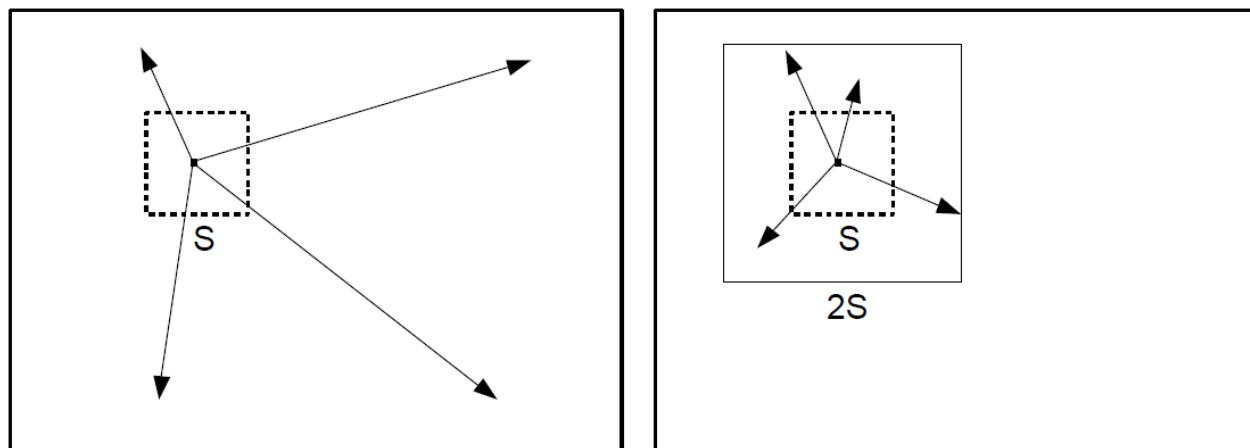


Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P. and Süsstrunk, S., 2012. SLIC superpixels compared to state-of-the-art superpixel methods. *IEEE transactions on pattern analysis and machine intelligence*, 34(11), pp.2274-2282.

SLIC (*Simple Linear Iterative Clustering*)

2. Za svaki centroid C_k ,

- Za svaki piksel i iz $2S \times 2S$ susedstva C_k izračunati udaljenost D između C_k i i
- Ako je $D < d(i)$ (tudaljenosti piksela i od centroma kome je piksel prethodno dodeljen), dodeli piksel i centru C_k i postavi $d(i) = D$



(a) standard k -means searches
the entire image

(b) SLIC searches
a limited region

Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P. and Süsstrunk, S., 2012. SLIC superpixels compared to state-of-the-art superpixel methods. *IEEE transactions on pattern analysis and machine intelligence*, 34(11), pp.2274-2282.

SLIC (*Simple Linear Iterative Clustering*)

3. Ažuriraj centroide (kao u *k-means*)

- Ponavljati korake 2-3 do konvergencije
- Na kraju, (opciono) možemo zameniti boju svakog piksela prosekom boje klastera kome piksel pripada

Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P. and Süsstrunk, S., 2012. SLIC superpixels compared to state-of-the-art superpixel methods. *IEEE transactions on pattern analysis and machine intelligence*, 34(11), pp.2274-2282.

SLIC (*Simple Linear Iterative Clustering*)

- Problem: kako definisati distancu D ?
 - Boja piksela u LAB prostoru $[l, a, b]$ se kreće u poznatom opsegu
 - Pozicija piksela $[x, y]$ se kreće u opsegu koji zavisi od veličine slike
 - Ova dva opsega mogu biti veoma različita. Moramo normalizovati bliskost u prostoru boja i prostornu bliskost kako jedna ne bi imala mnogo jači uticaj od druge

$$d_c = \sqrt{(l_i - l_j)^2 + (a_i - a_j)^2 + (b_i - b_j)^2}, \quad d_s = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$$

$$D = \sqrt{\left(\frac{d_c}{N_c}\right)^2 + \left(\frac{d_s}{N_s}\right)^2}$$

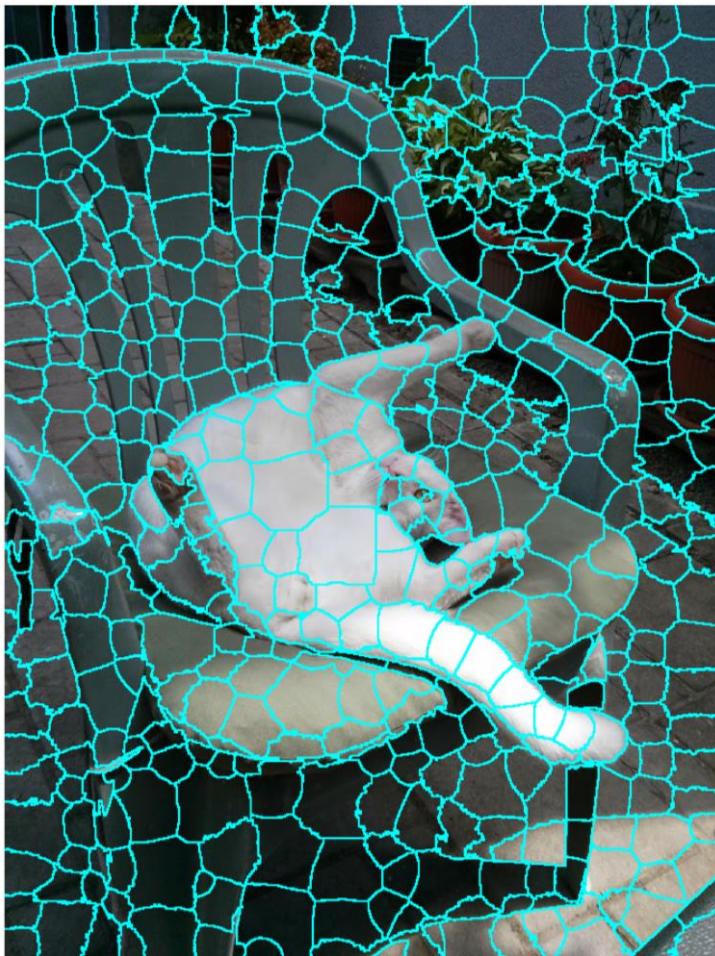
- N_c - maksimalna distanca u prostoru boja
- N_s - maksimalna prostorna distanca – već smo je ograničili $N_s = S = \sqrt{N/K}$, gde je N broj piksela, a K broj klastera

SLIC (*Simple Linear Iterative Clustering*)

- Za N_c je malo teže odrediti šta može biti
 - Rastojanja boja mogu veoma varirati od klastera do klastera i od slike do slike
 - U praksi, fiksiramo N_c na neku konstantu m koja reguliše nagodbu prostorne distance i distance u prostoru boja
 - Veliko m : superpikseli će biti kompaktniji
 - Malo m : superpikseli će se više vezati za ivice na slici
- Ovim se mera distance pojednostavljuje na:

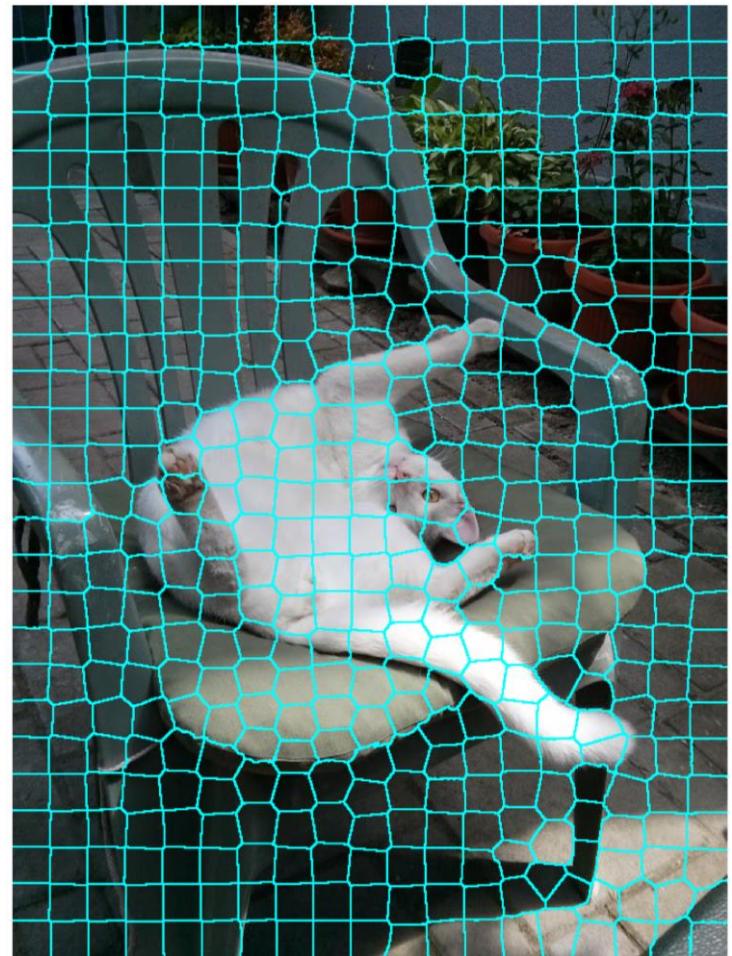
$$D = \sqrt{d_c^2 + \left(\frac{d_s}{S}\right)^2 m^2}$$

Superpikseli: kompaktnost



$m = 5$

superpikseli prate ivice



$m = 100$

superpikseli su kompaktniji

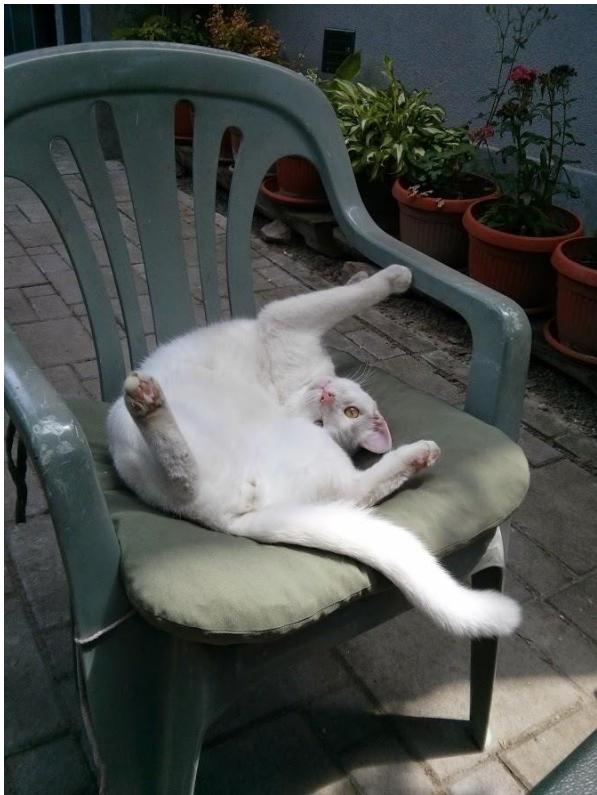
Broj superpiksela



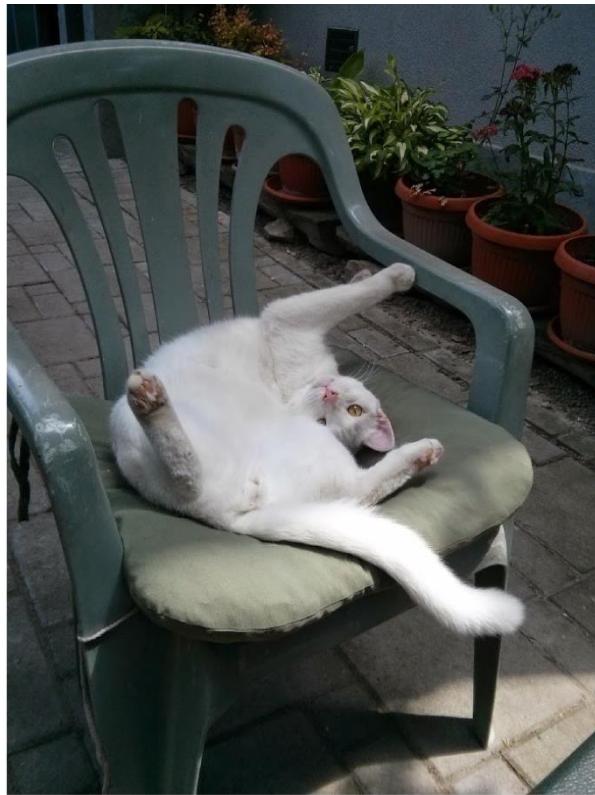
Fig. 1: Images segmented using SLIC into superpixels of size 64, 256, and 1024 pixels (approximately).

- Podešavanje prema tome koliko želite da superpikseli prate ivice

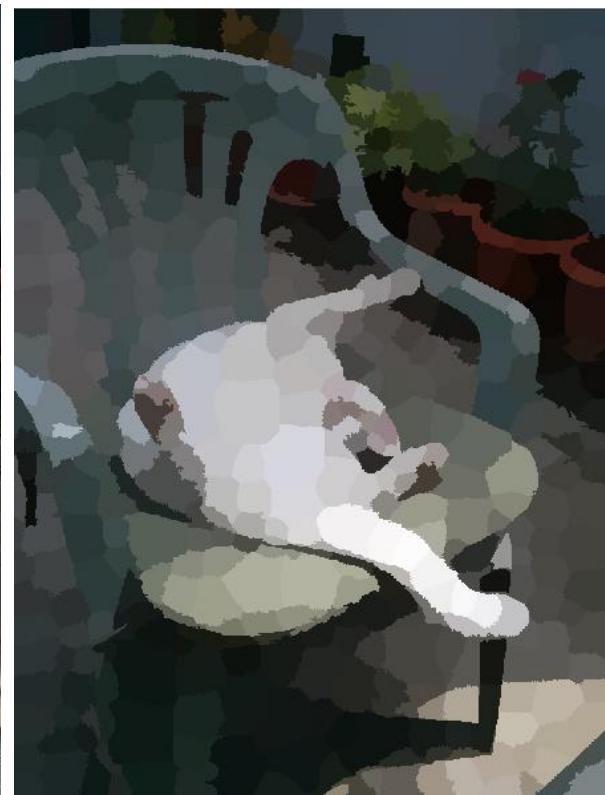
Broj superpiksela



$881 \times 668 = 595\,188$



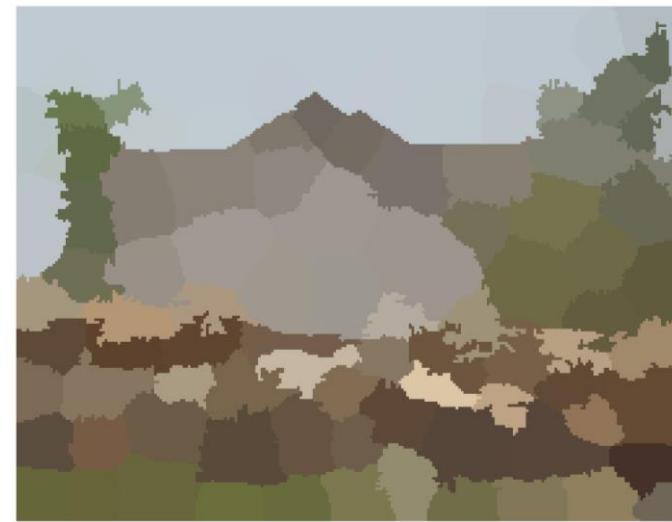
500 000 superpiksela,
Svaki piksel je zamenjen
prosekom boje klastera



500 superpiksela,
Svaki piksel je zamenjen
prosekom boje klastera

Segmentacija

- Nad superpixelsima možemo pustiti algoritam koji će ih grupisati u regije
 - Klasterovanje višeg nivoa:
 - Superpixelsima smo uklonili šum na originalnoj slici koji bi mogao smetati algoritmu za segmentaciju
 - Važne stvari su ostale, a uklonili smo nevažne stvari



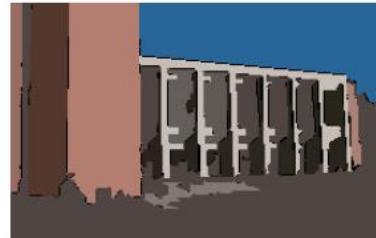
Segmentacija bazirana na klasterovanju

- Pored boje, klasterovanje može da koristi i druga obeležja. Na primer, teksture

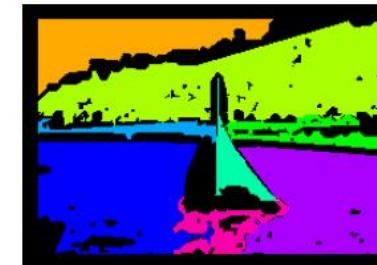
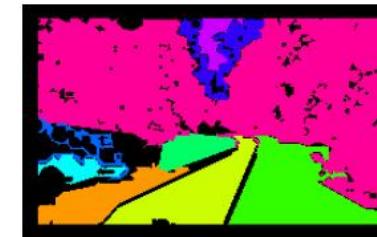
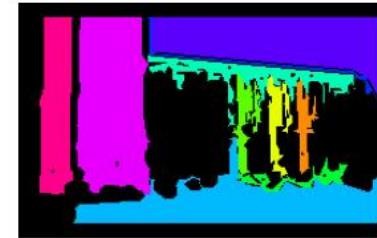
Original Images



Color Regions

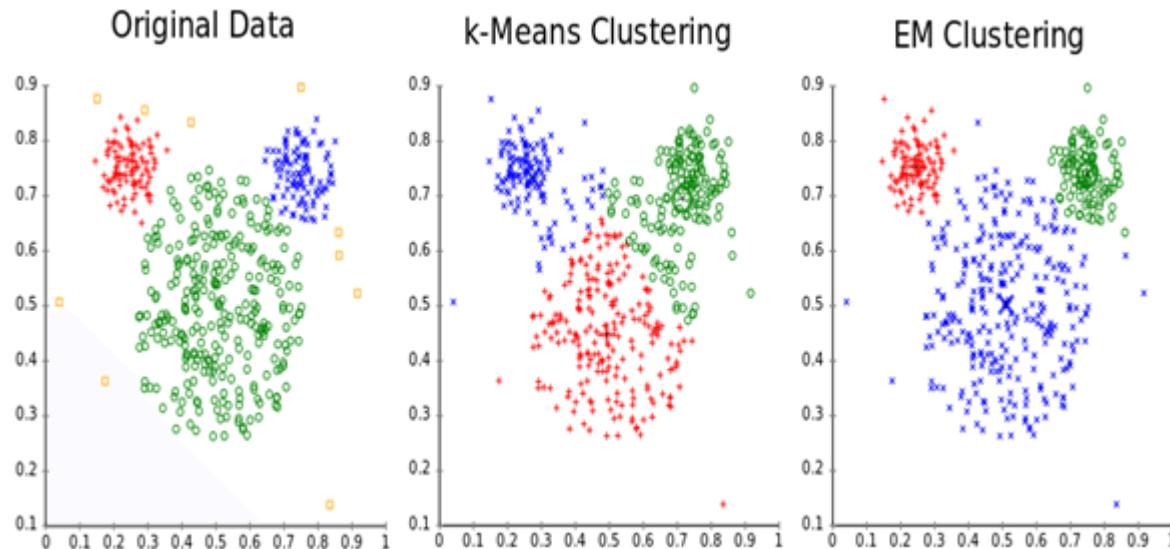


Texture Regions

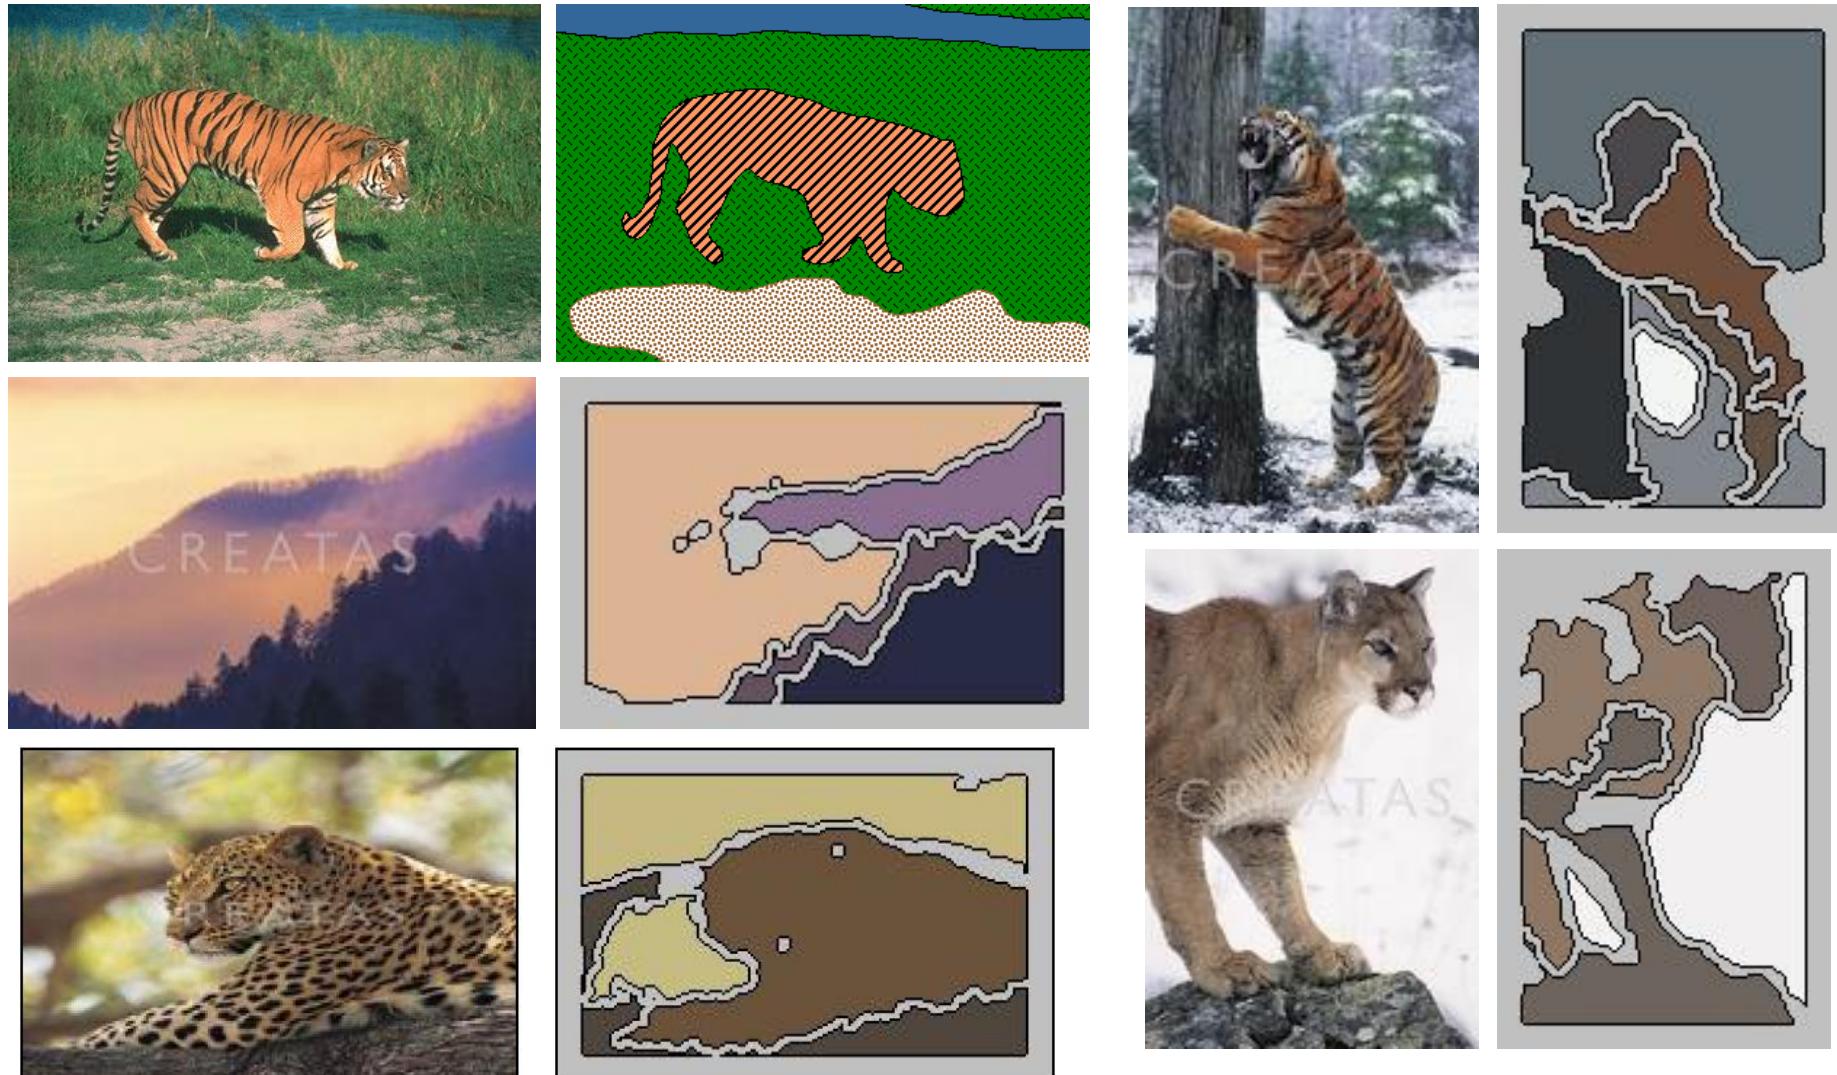


Segmentacija bazirana na klasterovanju

- Problem: segmentacija bazirane na histogramu i klasterovanju mogu proizvesti „neuredne“ regije
 - Kako se ovo može ispraviti?
- Model Gausovih Mešavina (*Gaussian Mixture Model*, GMM) se može koristiti kao probabilistički model za klasterovanje
 - Svaki klaster se modeluje Gausovom raspodelom
 - Za svaki klaster moramo odrediti parametre Gausijana



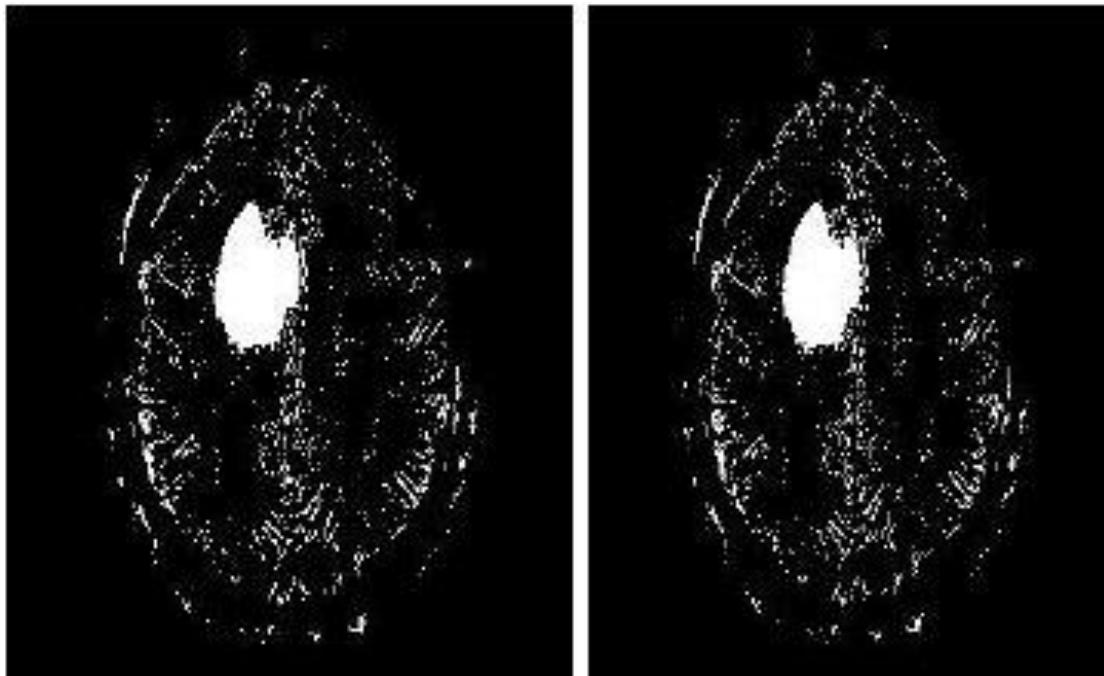
Primeri – UC Berkeley *Blobworld*



C. Carson, M. Thomas, S. Belongie, J. M. Hellerstein, and J. Malik, "Blobworld: a System for Region-Based Image Indexing and Retrieval (long version)," EECS Department, University of California, Berkeley, Tech. Rep. UCB/CSD-99-1041, 1999.

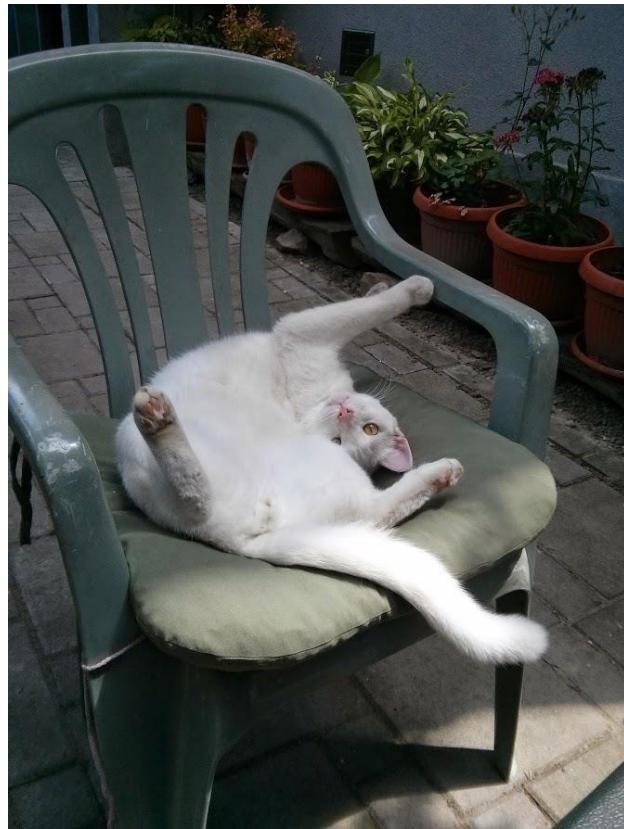
Segmentacija pomoću rasta regija

- *Region growing*
- Ako radimo segmentaciju pragom, možemo dobiti gomilu nepovezanih regija (iznad praga)
 - Binarne slike
 - Možemo primeniti morfološke operacije da malo pročistimo rezultate



- Umesto toga bismo nekada želeli jednu povezanu regiju sastavljenu od piksela koji pripadaju određenom susedstvu
- Recimo da želimo da kliknemo na jedan pixel regije i da automatski pronađemo *blob* piksela koji su na neki način slični toj tački

Poređenje segmentacije: rast regionala i prag



Segmentacija pomoću rasta regija

- Počinje od jednog piksela potencijalne regije

Iteration 5



Iteration 10



Iteration 20



- Regija se proširuje dodavanjem susednih piksela

Iteration 40



Iteration 70



Iteration 90



- Sve dok se potencijalni pikseli za dodavanje ne pokažu previše različitim

Biranje polaznog piksela

- Od ulazne slike $I(x, y)$ pravimo binarnu „seed image“ sliku $S(x, y)$ koja sadrži lokacije od interesa
- Možemo odabratи
 - Ručni odabir piksela
 - Skup polaznih (*seed*) piksela
 - Može se uraditi automatski, npr. primenimo segmentaciju pragom ili klasterovanje, a zatim svaku povezanu komponentu redukovati na jednu tačku (centroid, erozija,...)

Kada dodati susedni piksel u regiju?

- Može biti kriterijum zasnovan na sličnosti intenziteta
 - Dodajemo sve tačke koje su povezane sa (x, y) (8-susedstvo) čiji je intenzitet sličan intenzitetu te tačke: $|I(x, y) - I(x_i, y_i)| \leq T$
- Obično se koriste statistički testovi da se odredi koji pikseli se mogu dodati u regiju
 - Regija je populacija sa sličnom statistikom
 - Koristi se statistički test da se proveri da li se sused na granici regije uklapa u regiju populacije

Segmentacija pomoću rasta regiona

- Neka je R regija koja trenutno sadrži N piksela
- Neka je p piksel susedan regiji
- Srednja vrednost μ i varijansa σ^2 :

$$\mu = \frac{1}{N} \sum_{(r,c) \in R} I(r, c)$$

$$\sigma^2 = \frac{1}{N} \sum_{(r,c) \in R} (I(r, c) - \mu)^2$$

Segmentacija pomoću rasta regiona

- T -statistika:

$$T = \left(\frac{(N - 1)N}{N + 1} (p - \mu)^2 / \sigma^2 \right)^{\frac{1}{2}}$$

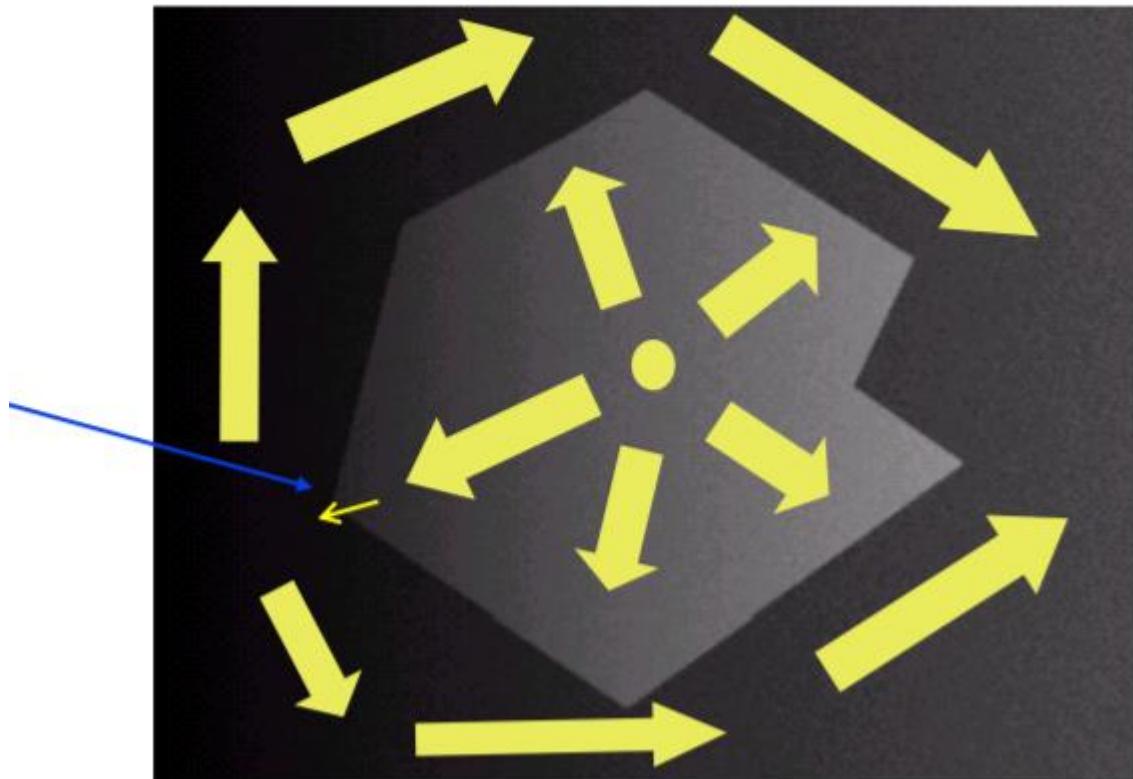
- Ima T_{N-1} distribuciju ako su svi pikseli u R i test piksel p nezavisni i identično distribuirani (*independent and identically distributed, i.i.d.*) Gausijani

Segmentacija pomoću rasta regiona

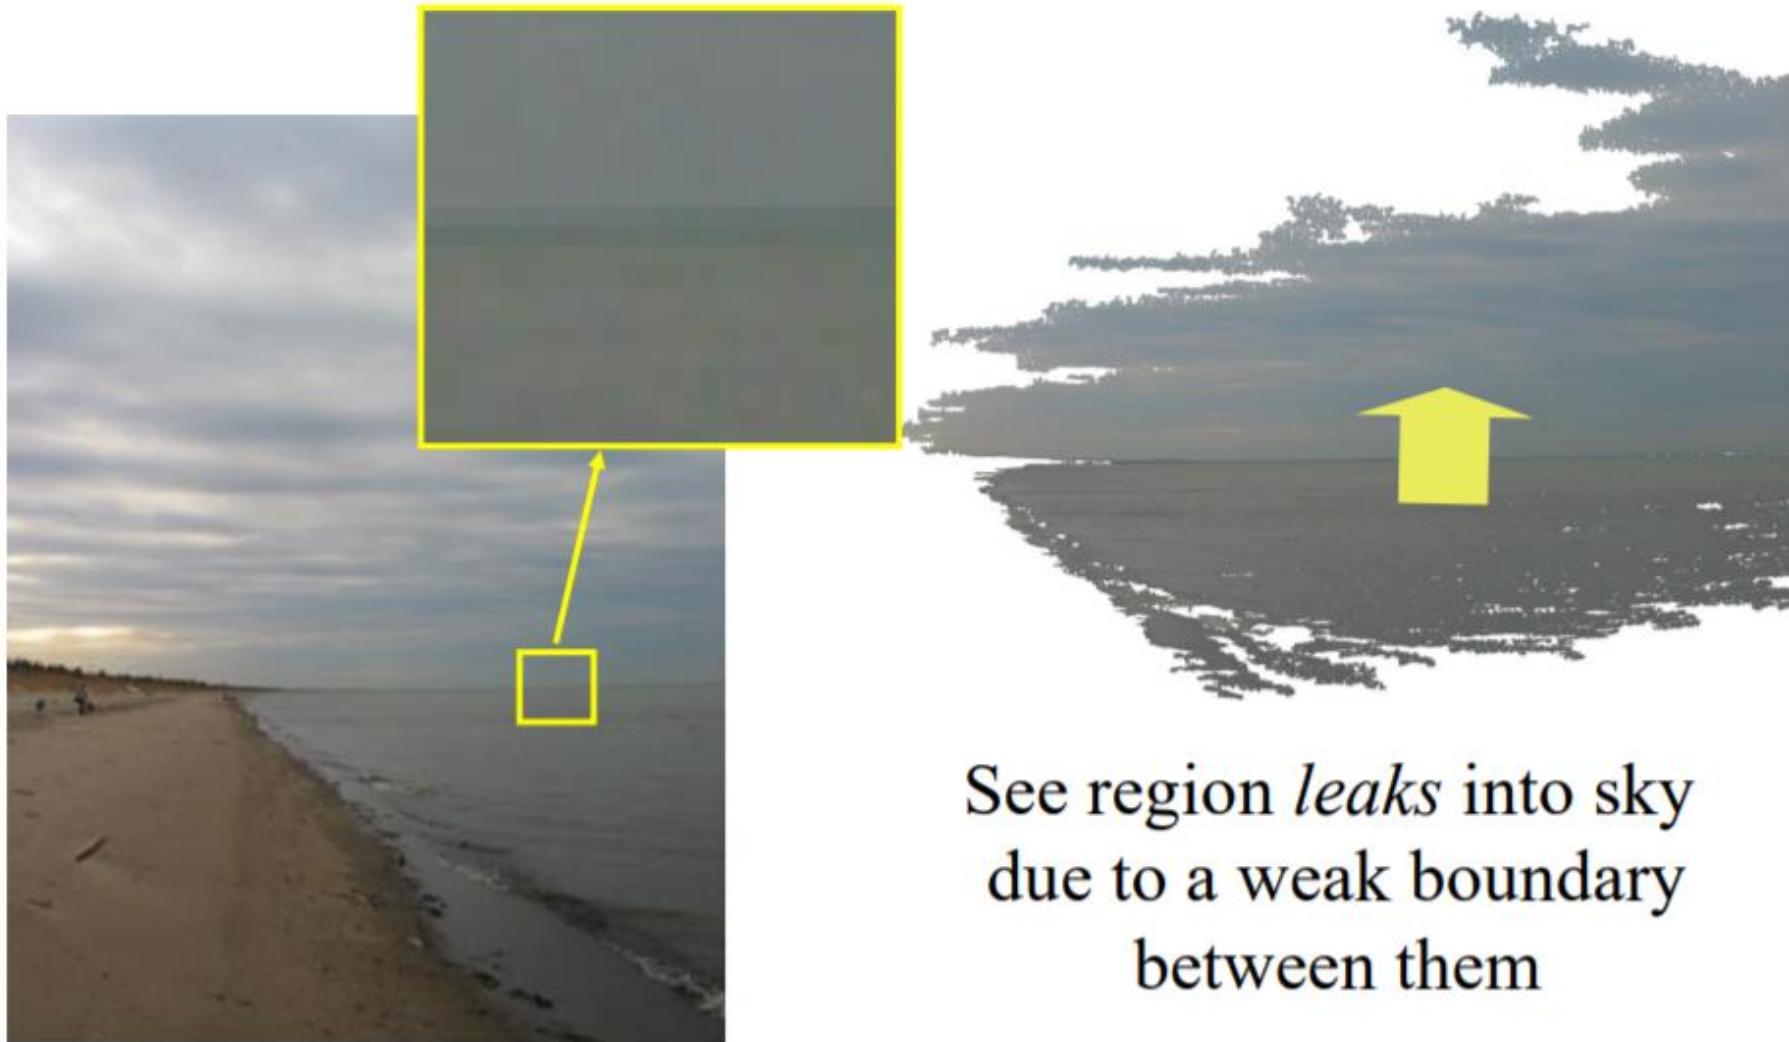
- Za T distribuciju, iz statističkih tabela možemo očitati verovatnoću $P(T \leq t)$ za dati stepen slobode i željeni nivo pouzdanosti (*confidence level*)
 - Potrebno je odabratи orgovarajući prag t
- Ako je izračunato $T \leq t$ za željeni nivo pouzdanosti, p se dodaje u regiju R i ažuriraju se μ i σ^2 regije
- Ako je izračunato T preveliko, smatra se da nije verovatno da p pripada populaciji piksela u R . Započeti novu regiju

Segmentacija pomoću rasta regiona - problem

Regija može da
„procuri“ kroz jednu
„slabu tačku“ granice

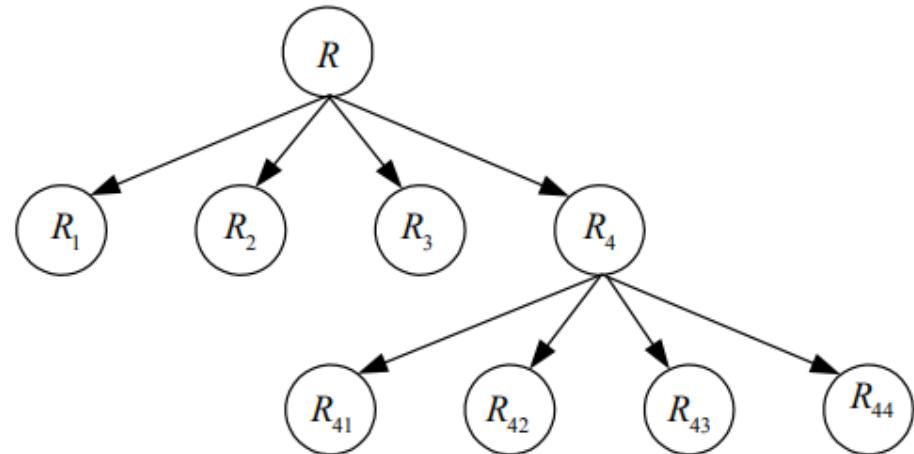
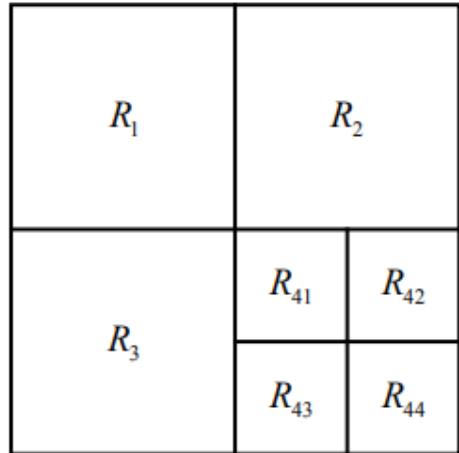


Segmentacija pomoću rasta regiona - problem



Segmentacija pomoću razdvajanja i spajanja regionala (*split-and-merge*)

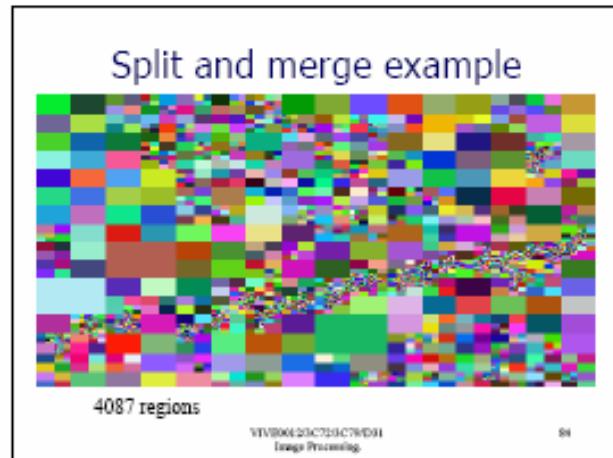
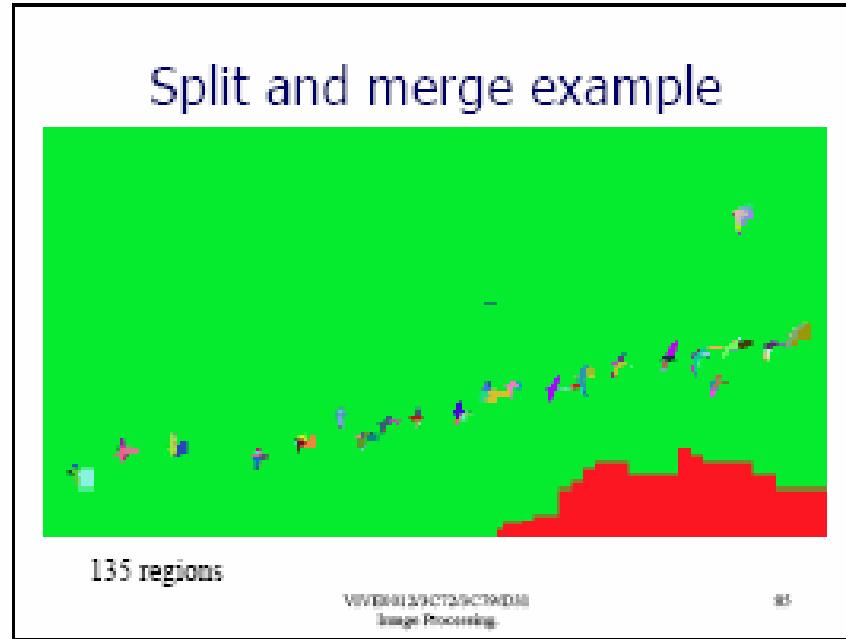
1. Za početnu regiju uzeti celu sliku
2. Ako regija nije uniformna, podeliti je na 4 kvadranta
3. Spojiti sve susedne dovoljno slične regije (isto uniformno obeležje)
4. Ponavljati korake 2-3 iterativno, sve dok nema više podele ili spajanja



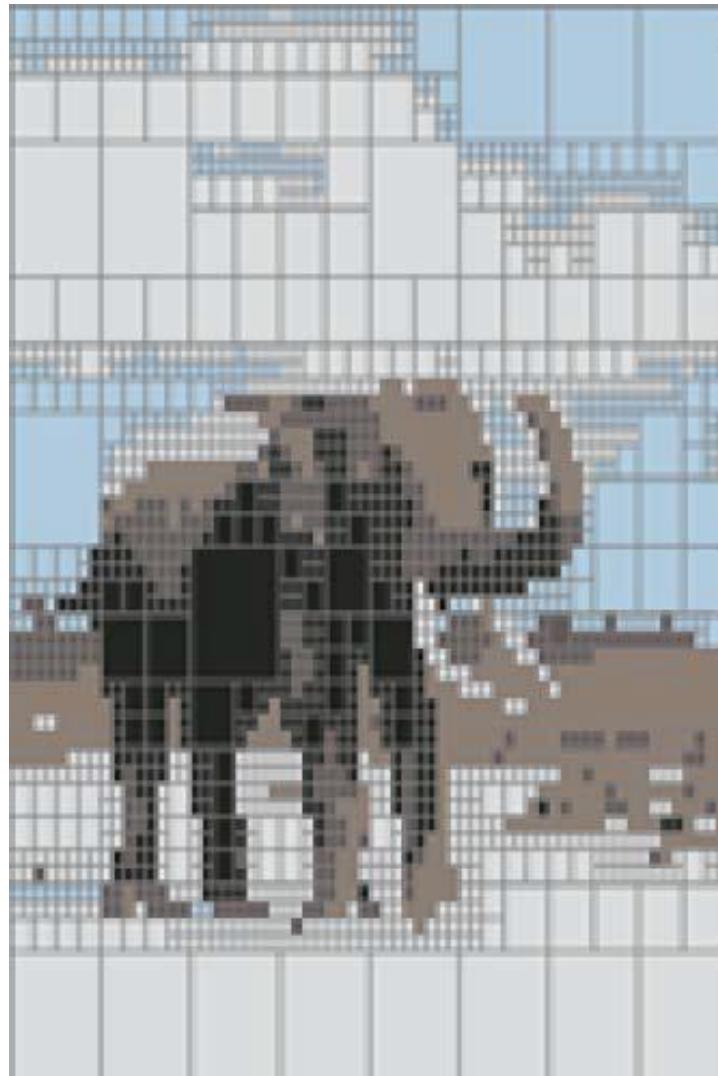
Segmentacija pomoću razdvajanja i spajanja regionalnih regija (*split-and-merge*)

- Moramo definisati:
 1. uniformnost/sličnost
 - Možemo uraditi na različite načine
 - Npr. razlika najveće i najmanje osvetljenosti piksela u regionu
 - Npr. varijansa osvetljenosti (ili druga statistička mera)
 2. Prag
 - Kada je regija dovoljno uniforma da je ne delimo na regije
 - Kada su regije dovoljno slične da možemo da ih spojimo
 3. Kriterijum zaustavljanja
 - Kada nema više deljenja/spajanja
 - Definisati najmanju veličinu bloka
- Nedostatak ove metode je blokovska struktura regionalnih regija u segmentiranoj slici

Segmentacija pomoću razdvajanja i spajanja regionala (split-and-merge)



Segmentacija pomoću razdvajanja i spajanja regionala (*split-and-merge*)



Segmentacija pomoću granica regiona

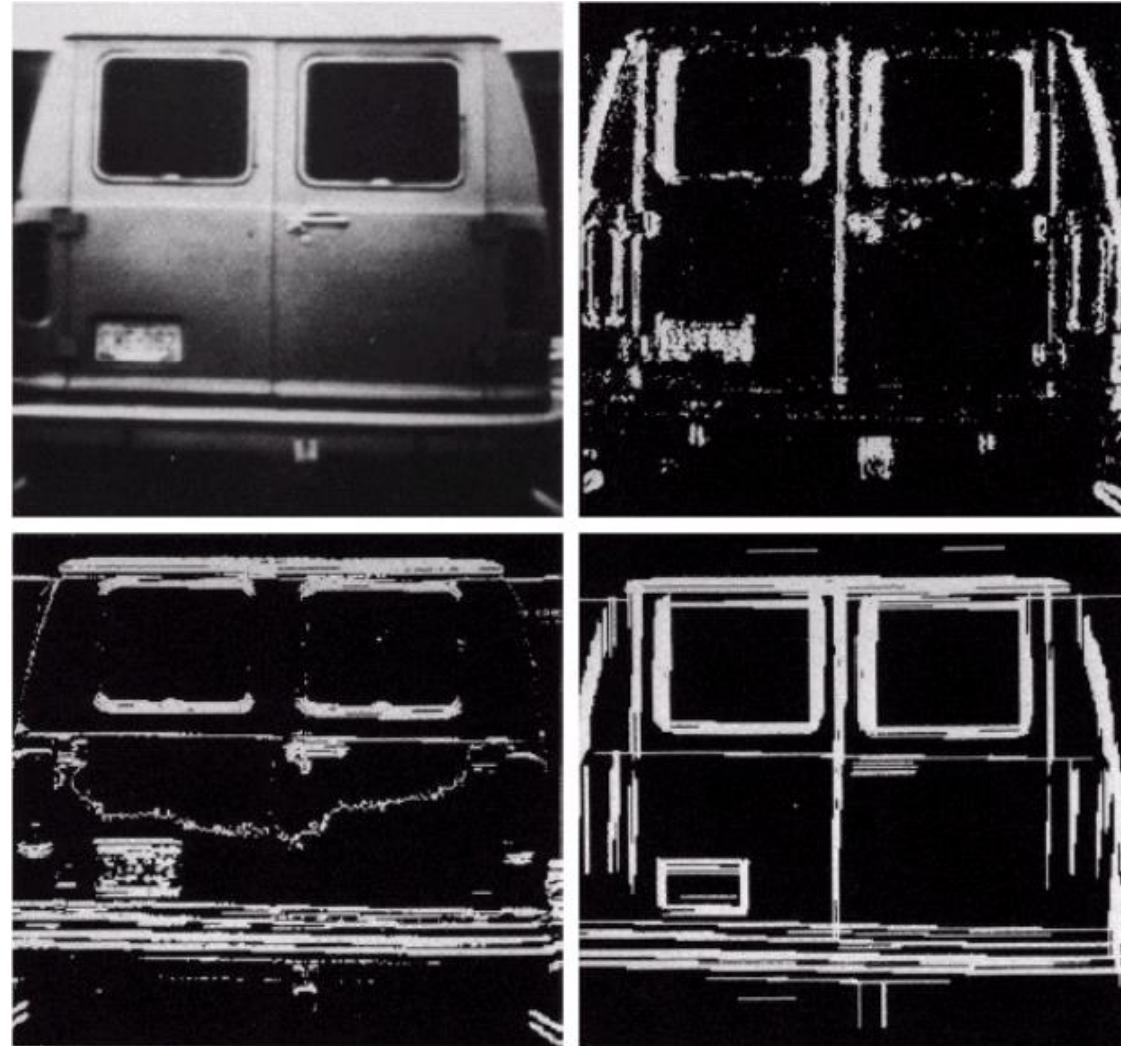
- Metode izdvajanja ivica generišu isprekidane granice objekata, a ne zatvorene krive
 - Posledica prisustva šuma, neuniformnog osvetljenja i drugih uticaja
- Za segmentaciju, moramo spojiti ivice u zatvorene konture
- Možemo koristiti
 - Lokalno povezivanje: analiza okoline pikela koji je označen nekom od metoda za detekciju ivica kao ivična tačka
 - Metode fitovanja polinomima ili pravolinijskim segmentima
 - Globana analiza: npr. Hough transformacija – tačke se povezuju ako pripadaju istoj krivoj određenog oblika

Lokalno povezivanje ivice

- Za svaku ivičnu tačku (x_0, y_0) analizira se njena bliska okolina (3×3 ili 5×5 piksela)
 - Sve tačke okoline koje su na osnovu nekog kriterijuma označene kao slične povezuju se u kompaktnu celinu – ivicu
- Dva osnovna kriterijuma
 - Magnituda gradijenta $|\nabla f(x, y) - \nabla f(x_0, y_0)| < E$
 - Pravac gradijenta $|\theta(x, y) - \theta(x_0, y_0)| < A$
 - Tačka (x, y) u okolini će biti povezana u ivicu samo ako zadovoljava oba kriterijuma

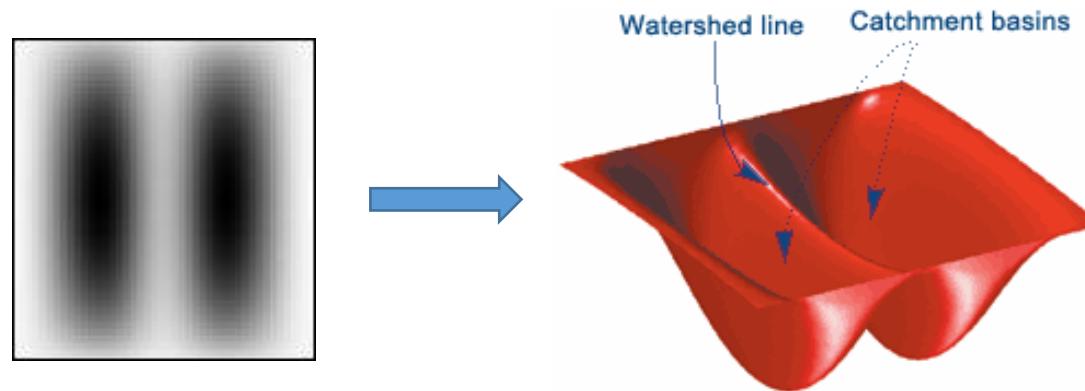
Lokalno povezivanje ivice

- Cilj: izdvojiti pravougaone objekte koji su kandidati za tablicu
- Gore desno i dole levo: G_x, G_y (Sobel)
- Povezivanje ivičnih regiona čija je magnituda gradijenta veća od 25, a ugao gradijenta se ne razlikuje za više od 15°
- Prepoznavanjem odnosa stranica, lako možemo izdvojiti tablicu od ostalih kandidata



Watershed segmentacija (razvođe)

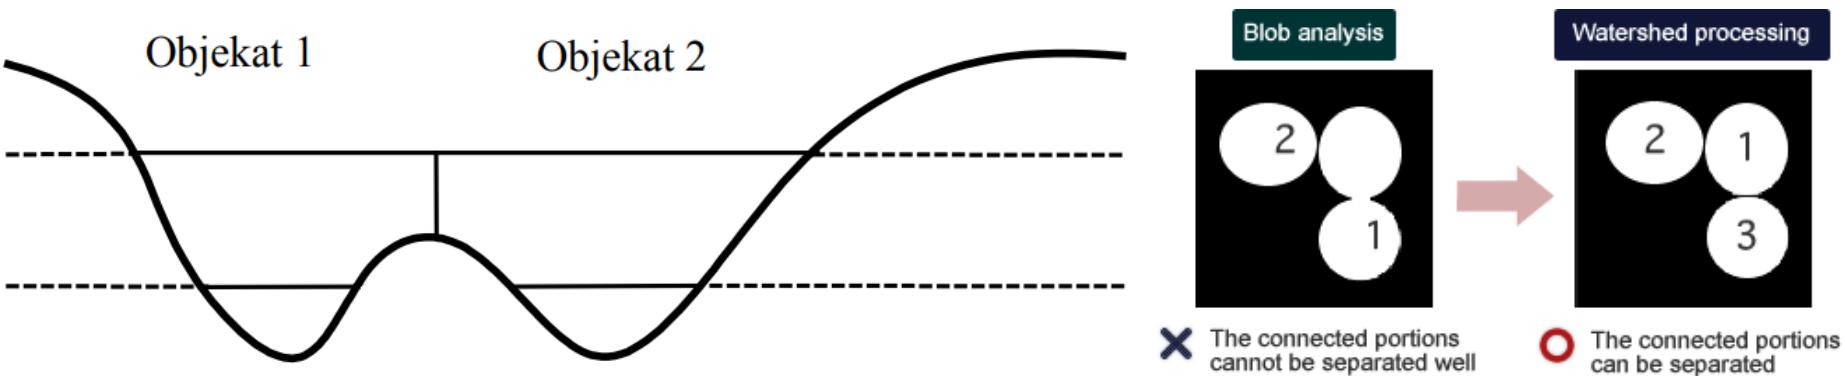
- Slika može biti interpretirana kao 3D površina sa „dolinama“ i „planinama“



- Možemo razlikovati tri tipa tačaka:
 - Tačke koje pripadaju minimumu regije
 - *Catchment basins*: tačke sa kojih bi kap vode pala u jedinstven minimum
 - *Watershed lines*: tačke sa kojih kap vode ima jednaku verovatnoću da padne u više od jednog minimuma
 - Ovo su tačke koje želimo da detektujemo – razdvajaju dva objekta reprezentovana „dolinama“

Watershed segmentacija

- Pretpostavimo da u svakoj tački minimuma ima „rupu“ i da se površ zaroni u vodu
- Voda bi ušla kroz rupe u minimumima i poplavila površinu
- Kako bi se izbeglo da se voda koja dolazi od dva različita minimuma izmeša, pravi se „brana“ kad god bi se desilo spajanje vodenih površina

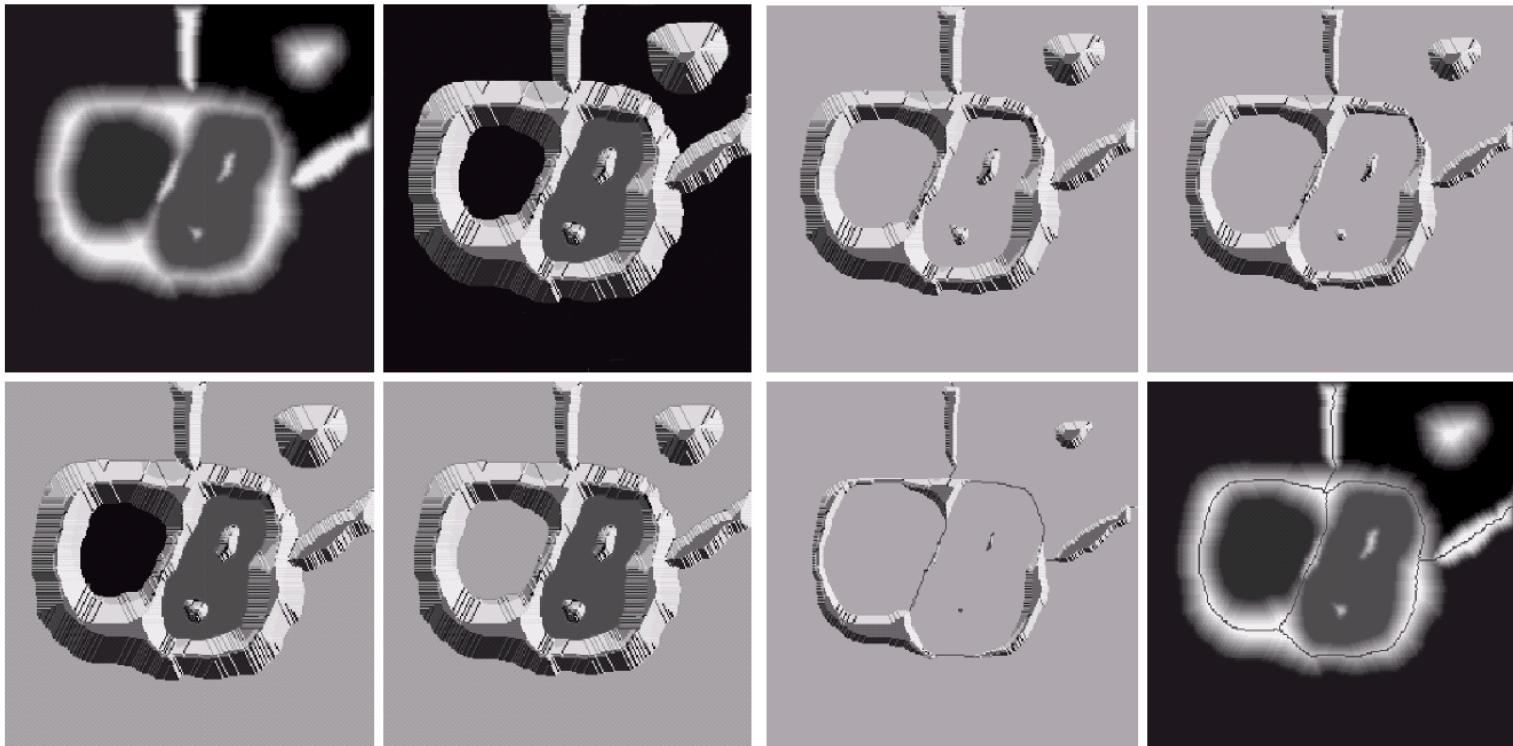


- Konačno, jedina stvar koja je vidljiva na površini bi bile ove „brane“. Ove „brane“ se zovu *watershed lines*.

Watershed segmentacija

a
b
c
d

FIGURE 10.44
(a) Original image.
(b) Topographic view.
(c)–(d) Two stages of flooding.



e
f
g
h

FIGURE 10.44 (Continued)
(e) Result of further flooding.
(f) Beginning of merging of water from two catchment basins (a short dam was built between them).
(g) Longer dams.
(h) Final watershed (segmentation) lines. (Courtesy of Dr. S. Beucher, CMM/Ecole des Mines de Paris.)

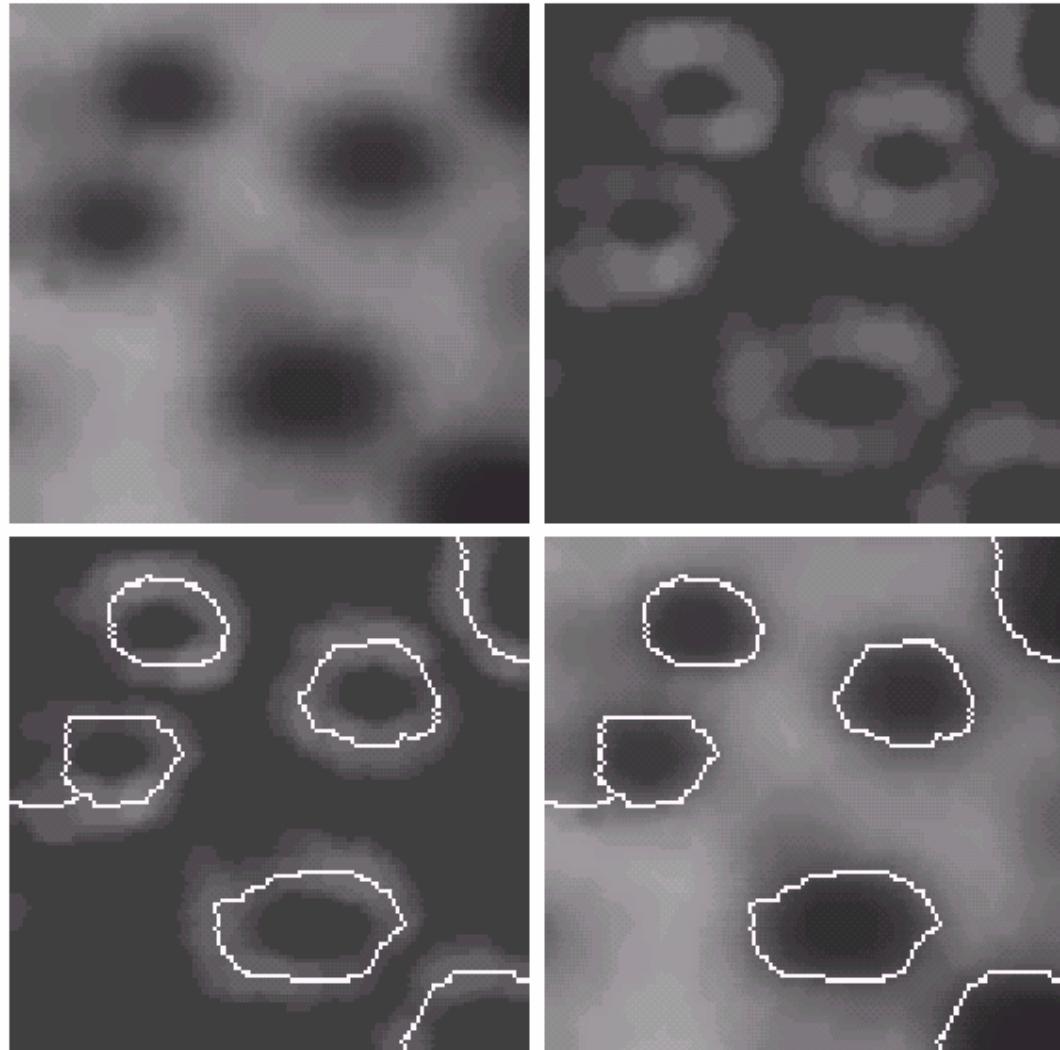
Watershed segmentacija

a b
c d

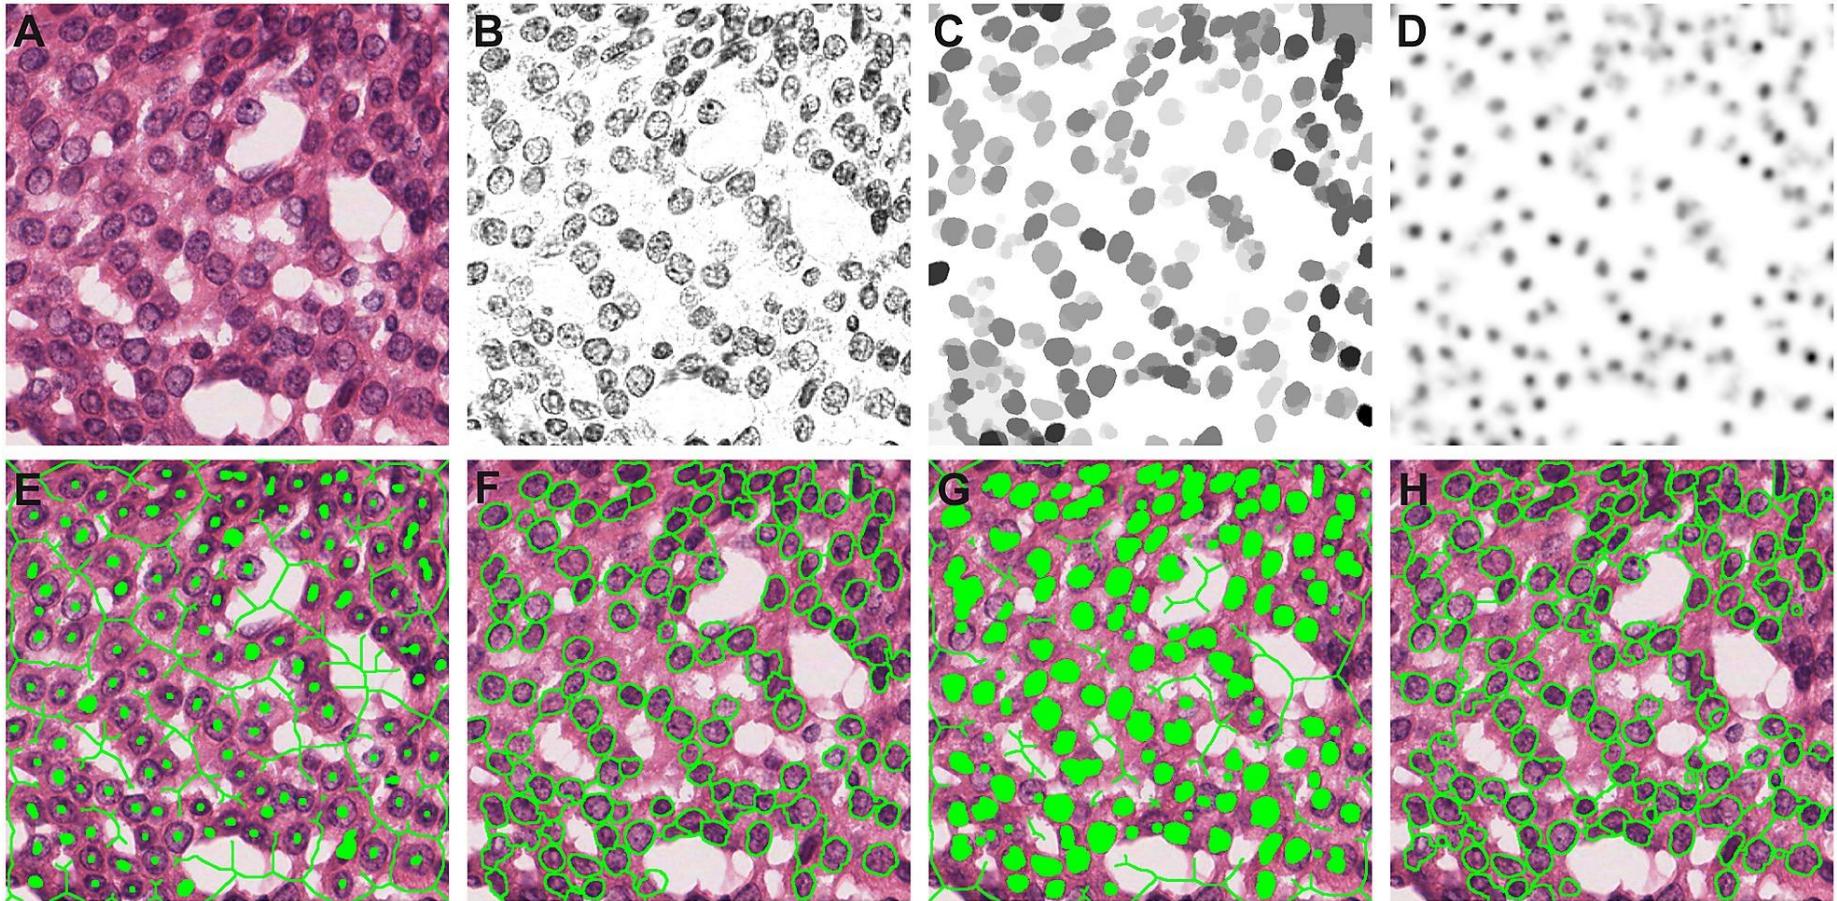
FIGURE 10.46

(a) Image of blobs. (b) Image gradient.
(c) Watershed lines.
(d) Watershed lines superimposed on original image.
(Courtesy of Dr. S. Beucher,
CMM/Ecole des Mines de Paris.)

- Jedna od glavnih primena je u ekstrakciji gotovo uniformnih (*bloblike*) objekata od pozadine
- Ivice dobijene segmentacijom su zatvorene konture



Watershed segmentacija



A) Original image. B) Hematoxylin channel. C) Pre-processed image (hematoxylin channel processed with series of morphological operations). D) Fast radial symmetry transform (FRST). E) FRST foreground and background markers. F) Watershed segmentation with FRST markers. G) Regional minima foreground and background markers. H) Watershed segmentation with regional minima markers

Veta, M., Van Diest, P.J., Kornegoor, R., Huisman, A., Viergever, M.A. and Pluim, J.P., 2013. Automatic nuclei segmentation in H&E stained breast cancer histopathology images. *PloS one*, 8(7), p.e70221.

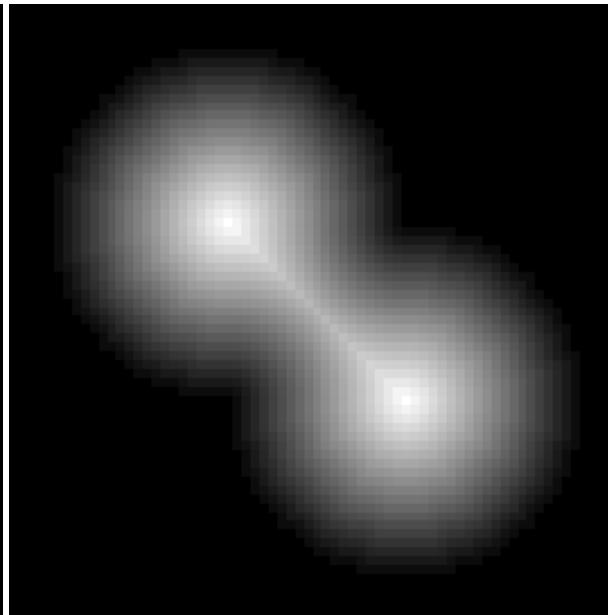
Watershed segmentacija

- Ključ za korišćenje *watershed* segmentacije: izmeniti sliku u drugu sliku čiji *catchment basins* predstavljaju objekte koji trebaju biti identifikovani
- Primeri:
 - Gradijent može biti korišćen za *grayscale* slike. *Catchment basins* bi u teoriji odgovarali homogenim regijama određenog nivoa sive na slici
 - *Distance transform* može biti korišćena na binarnim slikama
 - Ideja je da se kreiraju granice koje su najdalje moguće od centara objekata koji se preklapaju
 - *catchment basins* bi odgovarali objektima od interesa (*foreground*)

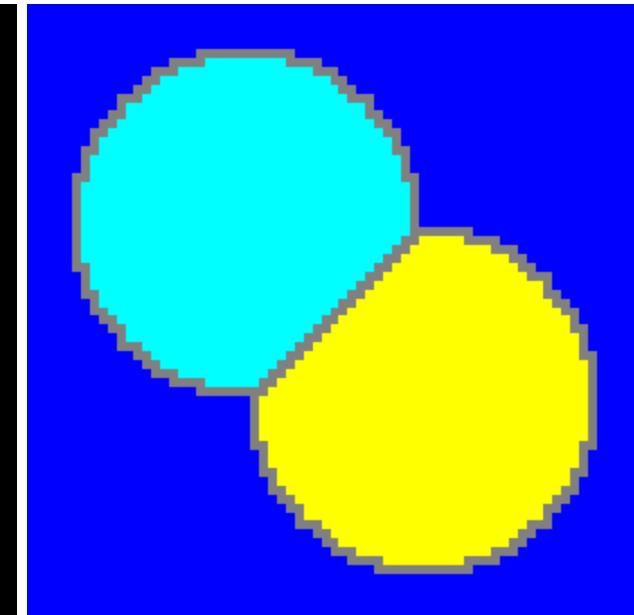
Watershed segmentacija



Binarna slika

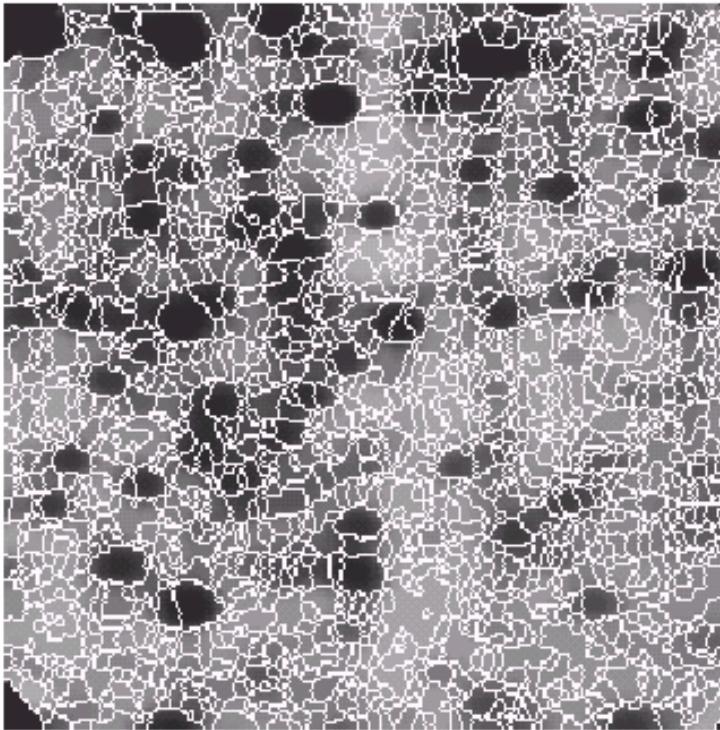
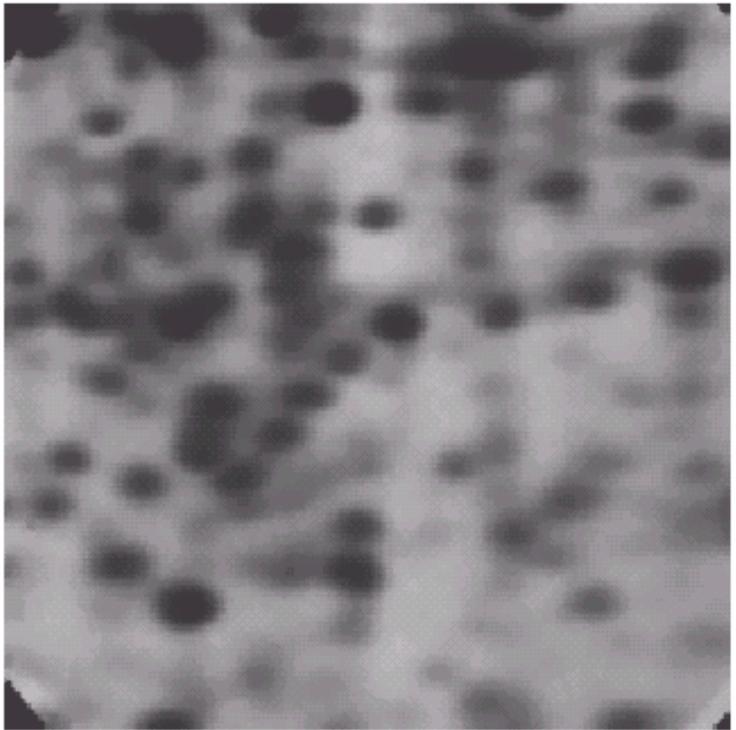


*Distance transform
komplementa binarne
slike*



*Watershed transform
primenjena na rezultat
*distance transform**

Watershed segmentacija



a b

FIGURE 10.47
(a) Electrophoresis image. (b) Result of applying the watershed segmentation algorithm to the gradient image. Oversegmentation is evident.
(Courtesy of Dr. S. Beucher, CMM/Ecole des Mines de Paris.)

- Slika je prekomerno segmentirana (*over-segmentation*)
 - Zato što ima veliki broj potencijalnih minimuma od kojih nisu svi relevantni (posledica šuma)
- Praktično rešenje: ograničiti broj dozvoljenih regija

Watershed segmentacija

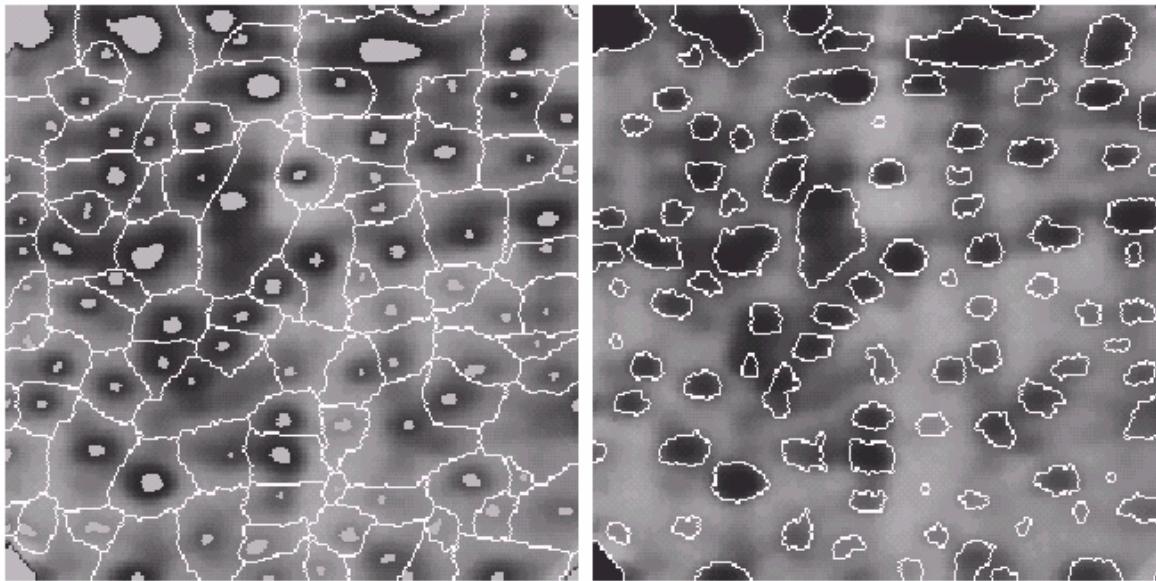


- Način da kontrolišemo prekomernu segmentaciju je da koristimo predefinisan skup markera kako bismo specificirali samo dozvoljene regionalne minimume (ubacivanje domenskog znanja)
- Trebaju nam:
 - Interni markeri (*Internal markers*) – unutar objekata od interesa
 - Eksterni markeri (*External markers*) – nalaze se na pozadini

Watershed segmentacija

- Interni markeri
 - Svaki odgovara jednom objektu
 - Okruženi su tačkama veće „nadmorske visine“
 - Tačke regije formiraju povezanu komponentu
 - Sve tačke u povezanim komponentama imaju isti intenzitet
- Eksterni markeri
 - Dele slike na regije gde je dozvoljeno da se nalaze lokalni minimumi
- Ovi markeri uvode ograničenja u proces segmentacije
 - U literaturi ima mnogo preporuka kako odabratи markere
 - Od jednostavnih algoritama baziranih na intenzitetu do kompleksnijih: boja, oblik, lokacija, tekstura,...
 - Uvodimo domensko znanje u proces segmentacije

Watershed segmentacija



a b

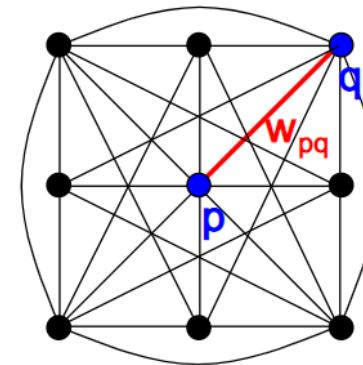
FIGURE 10.48

(a) Image showing internal markers (light gray regions) and external markers (watershed lines).
(b) Result of segmentation. Note the improvement over Fig. 10.47(b).
(Courtesy of Dr. S. Beucher,
CMM/Ecole des Mines de Paris.)

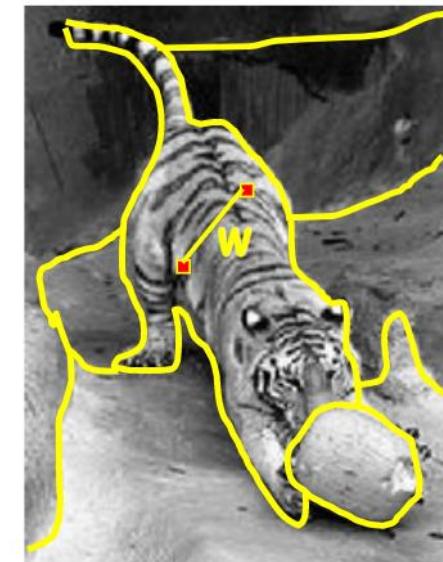
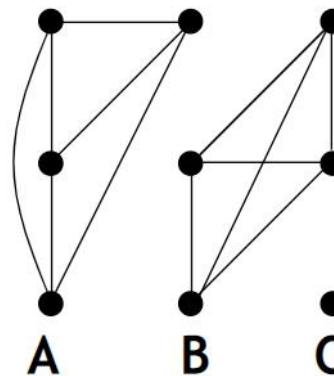
- Pronalazak internih markera: *Gaussian smoothing* + primena praga i (opciono) morfološke operacije
- Na datu sliku se primeni *watershed segmentacija* – dobijene tačke se proglose eksternim markerima
- Ove linije efikasno dele sliku na regije gde svaka ima jedan interni marker i deo pozadine
- Problem se redukuje na to da se svaka regija podeli na dva dela – može se primeniti *watershed* ili neka druga tehnika

Segmentacija slike bazirana na grafovima

- Slika je predstavljena grafom
 - Čvorovi odgovaraju pikselima (ili superpikselima)
 - Potpuno povezan graf
 - Grana između čvorova p i q ima težinu w_{pq} koja odgovara sličnosti čvorova



- Cilj je particonisanje čvorova u odvojene klastere
 - Sličnost čvorova unutar svakog klastera treba da bude velika, a sličnost čvorova različitih klastera treba da bude mala
 - Podelu ćemo uraditi brisanjem grana između sličnih segmenata



Segmentacija slike bazirana na grafovima

- Primer sličnosti čvorova:

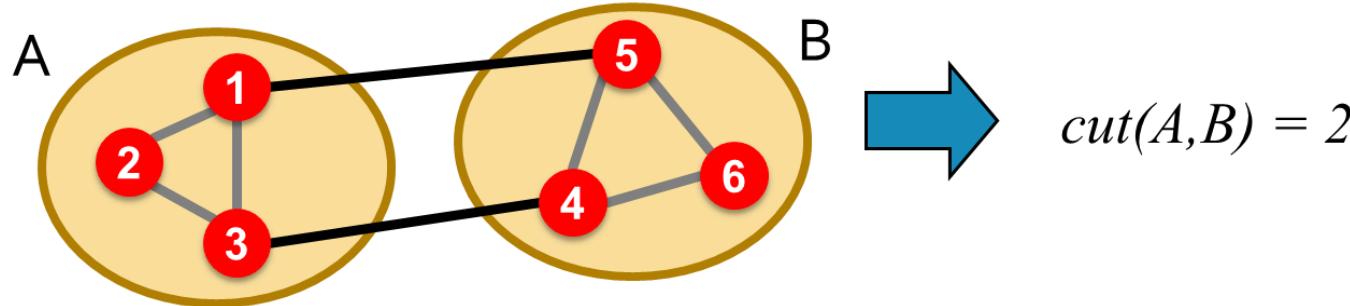
$$w_{pq} = \frac{1}{dist(p, q)} e^{-\frac{1}{2\sigma^2} \|I_p - I_q\|^2}$$

- Ako je $I_p \approx I_q \rightarrow e^{-\frac{1}{2\sigma^2} \|I_p - I_q\|^2} \approx e^0 = 1$
- Ako je $I_p \neq I_q \rightarrow e^{-\frac{1}{2\sigma^2} \|I_p - I_q\|^2} \approx e^{-\infty} = 0$

Segmentacija slike bazirana na grafovima

- Graf se može razbiti na dva odvojena skupa čvorova A i B uklanjanjem grana koje povezuju ove skupove čvorova

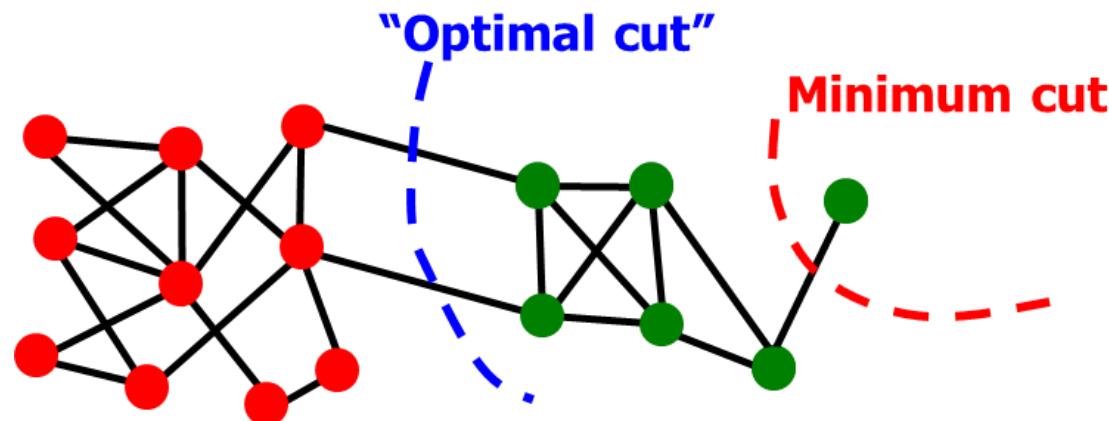
$$cut(A, B) = \sum_{u \in A, v \in B} w(u, v)$$



- Jedan način da se razbije graf jeste da se minimizuje cut

Segmentacija slike bazirana na grafovima

- Intuitivno rešenje za pronalaženje zajednica: preseci najmanji mogući broj grana
 - Kvalitet klastera je težina konekcija koje vode izvan klastera
- Ne radi uvek... Problem:
 - Favorizuje odsecanje malih grupa čvorova zato što uzima u obzir samo grane koje izlaze iz klastera
 - Ne uzima u obzir grane unutar klastera



Segmentacija slike bazirana na grafovima

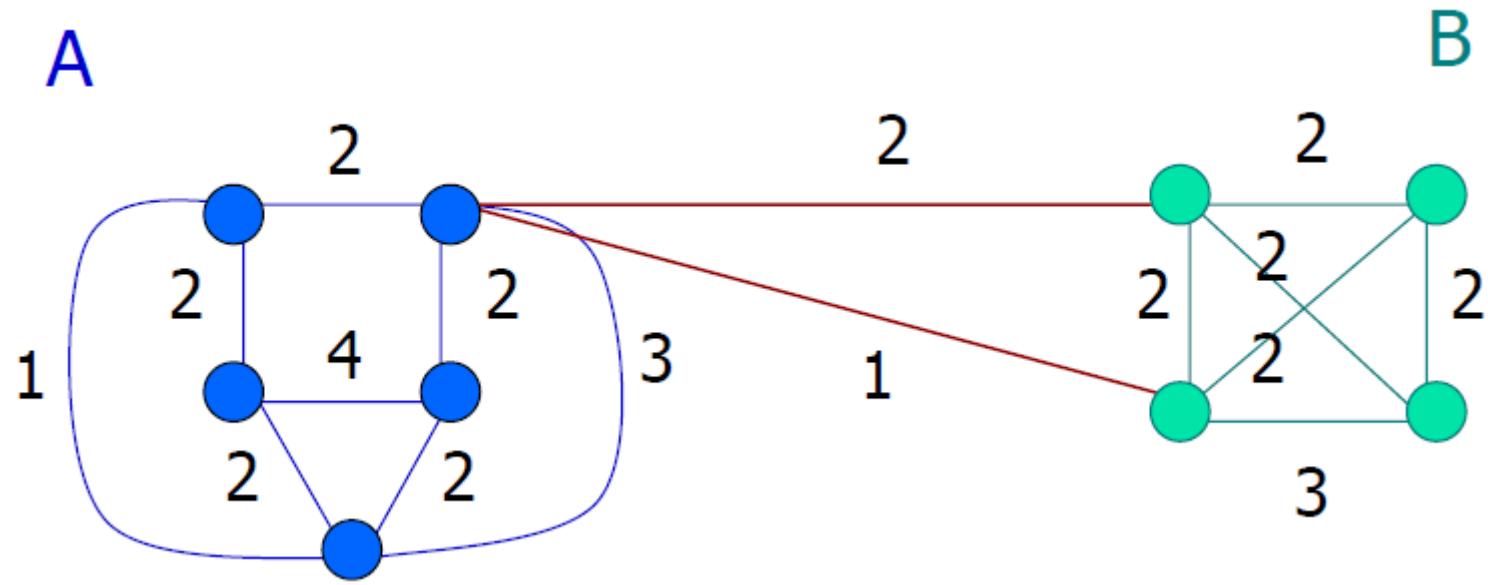
- Shi i Malik su predložili *normalized cut*:

$$Ncut(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)}$$

$$assoc(A, V) = \sum_{u \in A, t \in V} w(u, t)$$

$assoc(A, V)$ – koliko je skup čvorova A povezan sa grafom kao celinom (ukupna težina grana sa barem jednim čvorom u A)

Segmentacija slike bazirana na grafovima



$$Ncut(A, B) = \frac{3}{21} + \frac{3}{16}$$